

# Ökonometrie

Prof. Dr. Franziska Bönte

FH Wedel

Sommersemester 2024

# Gliederung des Moduls Ökonometrie

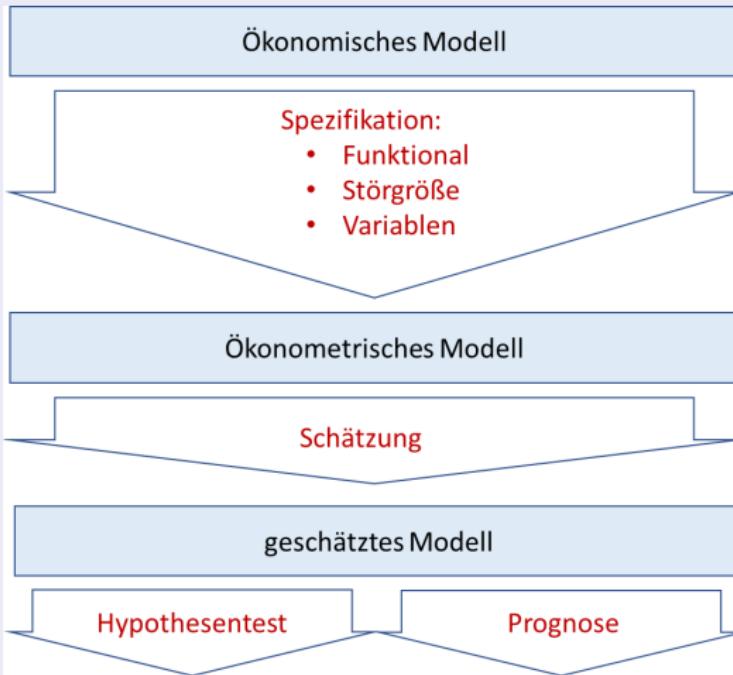
- ① Schätz- und Testverfahren im linearen Modell nach der kleinsten Quadrate-Methode
  - ① Einführung
  - ② Das bivariate Lineare Modell
  - ③ Annahmen in bivariaten Modell
  - ④ Eigenschaften von KQ-Schätzern im bivariaten Modell
  - ⑤ Modellauswahl anhand von t-Tests
  - ⑥ Prognosen im bivariaten Modell
  - ⑦ Das multivariate lineare Modell
  - ⑧ Tests der Annahmen des linearen Modells
- ② Schätzung verallgemeinerter linearer Modelle insbesondere Schätzen bei Autokorrelation der Störgröße (Aitken-Schätzung)
- ③ Allgemeine dynamische Modelle
- ④ Ökonometrische Mehrgleichungsmodelle

# Teil 1: Das Einfache Lineare Modell

## 1–1 Einführung

### Aufgaben ökonometrischer Analysen<sup>a</sup>

<sup>a</sup>Auer, L.v.; Einführung in die Ökonometrie; 2016



# Teil 1: Das Einfache Lineare Modell

## 1–1 Einführung

KQ-Regression  $\Leftrightarrow$  Lineares Modell

- KQ-Regression: Deskriptive Beschreibung von Daten
- Lineares Modell: Analyse einer Kausalbeziehung von Daten zueinander
- KQ-Regression = Ausgangspunkt des Linearen Modells

Deskriptiv  
beschreibt Dati

Ausgangspunkt  
für Lineare Modell

Causal Beziehungen  
zu erneut zu Analysen

# Teil 1: Das Einfache Lineare Modell

## 1–2 Das bivariate Lineare Modell

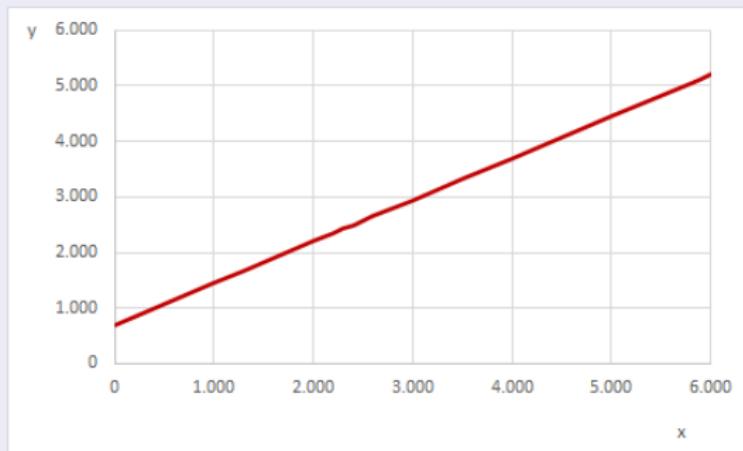
$$Y_i = \beta_0 + \beta_1 \cdot x_i + U_i$$

# Teil 1: Das Einfache Lineare Modell

## 1–2 Das bivariate Lineare Modell

Beispiele für Schätzer der Parameter eines Linearen Modells

Sei  $Y_i = 700 + 0,5 \cdot x_i \forall i$  das „wahre“ Modell

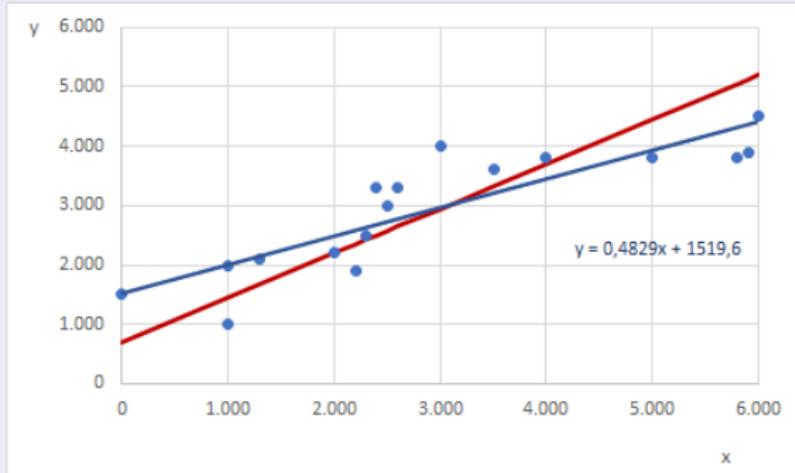


# Teil 1: Das Einfache Lineare Modell

## 1–2 Das bivariate Lineare Modell

Beispiele für Schätzer der Parameter eines Linearen Modells: 1. Stichprobe

$i$	$x_i$	$y_i$
1	0	1.520
2	1.000	1.000
3	1.000	2.000
4	1.300	2.100
5	2.000	2.200
6	2.200	1.900
7	2.300	2.500
8	2.400	3.300
9	2.500	3.000
10	2.600	3.300
11	3.000	4.000
12	3.500	3.600
13	4.000	3.800
14	5.000	3.800
15	5.800	3.800
16	5.900	3.900
17	6.000	4.500

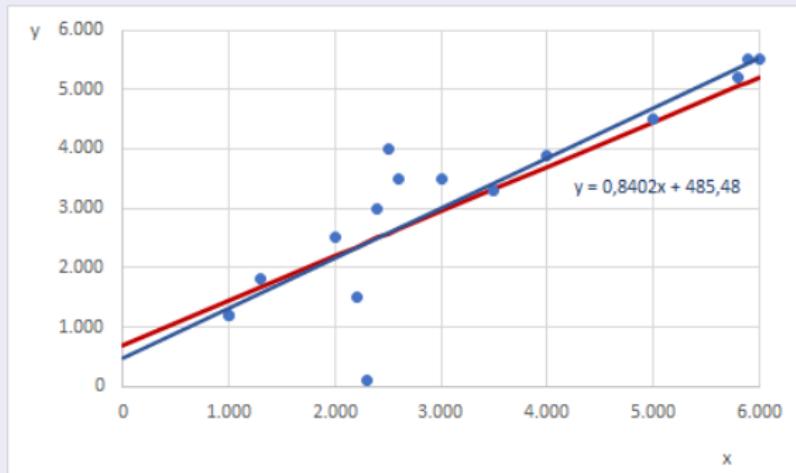


# Teil 1: Das Einfache Lineare Modell

## 1–2 Das bivariate Lineare Modell

Beispiele für Schätzer der Parameter eines Linearen Modells: 2. Stichprobe

$i$	$x_i$	$y_i$
1	0	
2	1.000	1.200
3	1.000	1.200
4	1.300	1.800
5	2.000	2.500
6	2.200	1.500
7	2.300	2.100
8	2.400	3.000
9	2.500	4.000
10	2.600	3.500
11	3.000	3.500
12	3.500	3.300
13	4.000	3.900
14	5.000	4.500
15	5.800	5.200
16	5.900	5.500
17	6.000	5.500

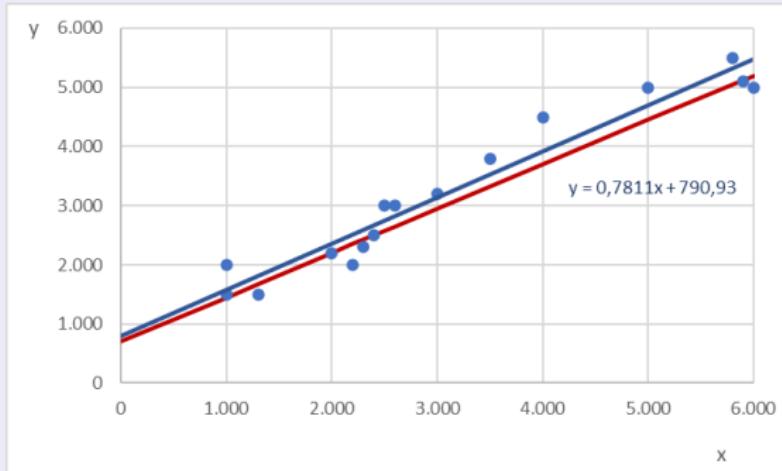


# Teil 1: Das Einfache Lineare Modell

## 1–2 Das bivariate Lineare Modell

Beispiele für Schätzer der Parameter eines Linearen Modells: 3. Stichprobe

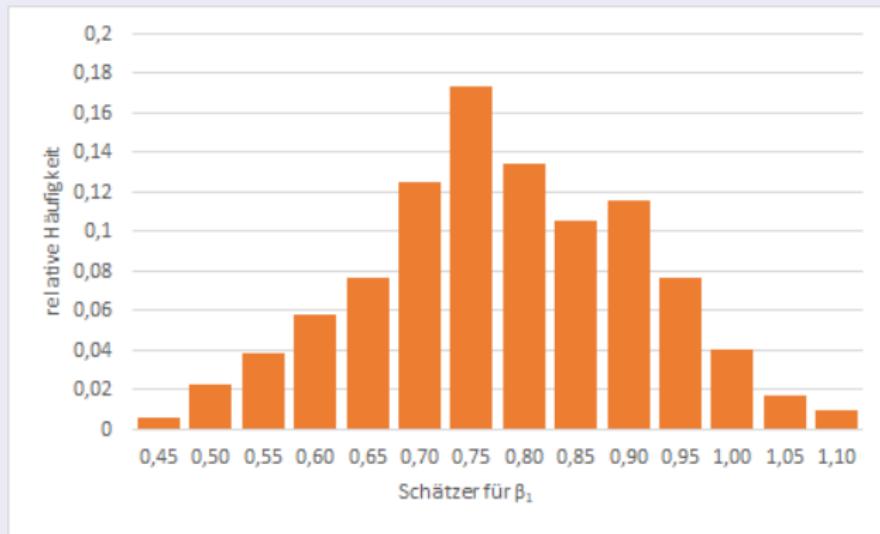
$i$	$x_i$	$y_i$
1	0	
2	1.000	2.000
3	1.000	1.500
4	1.300	1.500
5	2.000	2.200
6	2.200	2.000
7	2.300	2.300
8	2.400	2.500
9	2.500	3.000
10	2.600	3.000
11	3.000	3.200
12	3.500	3.800
13	4.000	4.500
14	5.000	5.000
15	5.800	5.500
16	5.900	5.100
17	6.000	5.000



# Teil 1: Das Einfache Lineare Modell

## 1–2 Das bivariate Lineare Modell

Empirische Verteilung für  $\hat{\beta}_1$  bei einem Stichprobenumfang  $n = 520$



# Teil 1: Das Einfache Lineare Modell

## 1–3 Annahmen im bivariaten Linearen Modell

### Annahmen zur funktionalen Spezifikation des Modells

- das Modell enthält alle relevanten exogenen Variablen
- das Modell enthält keine nicht-relevanten exogenen Variablen
- der Zusammenhang von  $x_i$  und  $Y_i$  ist linear
- die Parameter  $\beta_0$  und  $\beta_1$  sind für alle Beobachtungen  $(x_i; Y_i)$  konstant

# Teil 1: Das Einfache Lineare Modell

## 1–3 Annahmen im bivariaten Linearen Modell

### Beispiel: Absatzmenge

Nehmen wir an, wir möchten die Absatzmenge unseres Produktes analysieren und haben dazu die letzten 10 Preisänderungen sowie die zu diesen Preisen verkauften Mengen notiert:

Preis (in EURO)	Absatz (in Tsd. Stück)	Preis (in EURO)	Absatz (in Tsd. Stück)
10	120	17	77
11	100	18	70
12	90	20	75
15	80	23	60
16	82	30	30

(1) causal bezügliche Abstimmung

$$Y = f(X)$$

Q genauer funktionssinn Form bestimmen  $y = \beta_0 + \beta_1 \cdot x$

# Teil 1: Das Einfache Lineare Modell

## 1–3 Annahmen im bivariaten Linearen Modell

Warum gibt es ein Störgröße  $U$ ?

- unsystematische Erhebungs- und Messfehler durch Verwendung von Näherungsvariablen (sog. Proxyvariablen)
- bestimmte exogene Variablen sind nicht im Modell enthalten, da Erhebung unmöglich oder zu kostenintensiv ist
- das menschliche Verhalten ist teilweise unberechenbar

⇒ Die Störgrößen schwanken rein zufällig um den Wert 0

⇒ Die Störgröße ist eine Zufallsvariable.

(2) Beobachtungswert hinzufügen:  $i$

$(x_i \ y_i)$

(3) Störgröße hinzufügen:  $u_i$  (B.s. Busse fahren nicht und wie wollen Abzüge von Verkaufserlösen auf Wk.)

$$y_i = \beta_0 + \beta_1 x_i + u_i$$

# Teil 1: Das Einfache Lineare Modell

## 1–3 Annahmen im bivariaten Linearen Modell

$$\text{Cov}(U_i, U_j) = 0$$

Annahmen zur Störgröße  $U$

- Weiße Rauschen:

- Erwartungstreue:  $E(U_i) = 0$  für  $i = 1; \dots; n$
- Homoskedastie:  $\text{Var}(U_i) = \sigma^2$  für  $i = 1; \dots; n$
- Unabhängigkeit:  $\text{Cov}(U_i; U_j) = 0 \forall i \neq j$

- Exogenität der Regressoren:  $\text{Cov}(U_i; X_i) = 0$

- $S_x^2 > 0$  → linear unabhängig von den Regressoren

- Normalverteilung:  $U_i \sim F_{\text{NV}}(\mu = 0; \sigma^2)$

das Wollen wir haben  
Weiße Rauschen  
Heteroskedastiz.

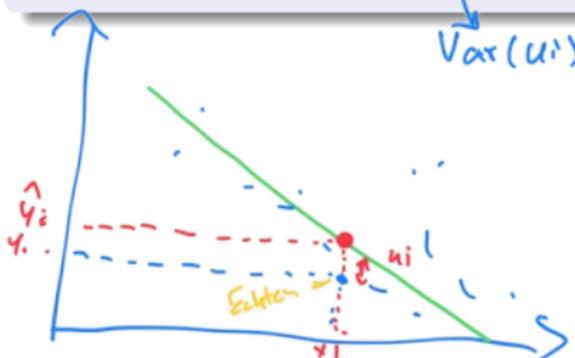
im Ökonometrie ist leider was unmöglich  
nicht möglich



Die Kovarianz  $n_i$   
mit sich selbst

$$\text{Var}(U_i) = \sigma^2$$

Homoskedastizität  
unabhängig von  
exogenen Werten oder  
oder  $X$ . Verhält sich  
endogen gleich  
(Realität ist nicht so)



# Teil 1: Das Einfache Lineare Modell

## 1–4 Eigenschaften der Schätzfunktionen

Sei  $y_i = \beta_0 + \beta_1 x_i + u_i$   
Schätzen für  $\beta$ :  $\hat{\beta}$

$$\hat{\beta}_1 = \frac{\bar{y}_x - \bar{y}_\cdot \bar{x}}{\bar{x}^2 - \bar{x}^2} = \frac{s_{yx}}{s_x^2}$$

### Eigenschaften der Schätzer für $\beta_0$ und $\beta_1$

- ① Erwartungswert
- ② Varianz
- ③ Verteilungsfunktion

oder

$$= \frac{\sum_i (y_i - \bar{y})(x_i - \bar{x})}{\sum_i (x_i - \bar{x})^2}$$

$$\bar{Y} = \beta_0 + \beta_1 \bar{x} + \bar{u}$$

$$y_i - \bar{y} = \underbrace{\beta_0 + \beta_1 x_i + u_i}_{u_i} - (\beta_0 + \beta_1 \bar{x} + \bar{u})$$

$$y_i - \bar{y} = \beta_0 + \beta_1 x_i + u_i - \beta_0 - \beta_1 \bar{x} - \bar{u}$$

$$\hat{\beta}_1 = \frac{\sum (y_i - \bar{y})(x_i - \bar{x})}{\sum (x_i - \bar{x})^2}$$

$$= \frac{\sum (\beta_1 \cdot (x_i - \bar{x}) + (u_i - \bar{u})) (x_i - \bar{x})}{\sum (x_i - \bar{x})^2}$$

# Teil 1: Das Einfache Lineare Modell

## 1–4 Eigenschaften der Schätzfunktionen

Erwartungswerte der Schätzer für  $\beta_0$  und  $\beta_1$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \cdot \bar{x} = \bar{y} - \frac{\sum_{i=1}^n (u_i + \bar{u})(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$E(\hat{\beta}_0) = \beta_0 = \beta_1 + \frac{\sum_{i=1}^n u_i(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} + \bar{u} \cdot \frac{\sum_{i=1}^n (x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} = 0$$

$$E(\hat{\beta}_1) = \beta_1 = \frac{\sum_{i=1}^n u_i(-x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} + \bar{u} \cdot \frac{\sum_{i=1}^n (-x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$= \beta_1 + \frac{\sum_{i=1}^n u_i(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$= \beta_1 + \frac{u_1(x_1 - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} + \frac{u_2(x_2 - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} + \dots$$

$$E(\hat{\beta}_1) = E[\beta_1 + \dots]$$

# Teil 1: Das Einfache Lineare Modell

$E(\beta_1) = E(\rho_1) + \frac{E(u(x_i - \bar{x}))}{\sum_{i=1}^n (x_i - \bar{x})^2}$

## 1–4 Eigenschaften der Schätzfunktionen

Varianzen von  $\hat{\beta}_0$  und  $\hat{\beta}_1$

$$\begin{aligned} \text{Var}(\hat{\beta}_1) &= \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \\ &\quad + \frac{E(u_n) \cdot (x_n - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} \\ &\quad \hat{E}(\hat{\beta}_1) = \beta_1 \end{aligned}$$

$$\text{Var}(\hat{\beta}_0) = \sigma^2 \left( \frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right)$$

$$\text{Cov}(\hat{\beta}_0; \hat{\beta}_1) = -\sigma^2 \frac{\bar{x}}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

# Teil 1: Das Einfache Lineare Modell

## 1–4 Eigenschaften der Schätzfunktionen

### BLUE

- B — Best
- L — Linear
- U — Unbiased
- E — Estimator

# Teil 1: Das Einfache Lineare Modell

## 1–5 Modellauswahl

### Statistische Hypothese

Eine statistische Hypothese  $H_0$  ist eine Annahme über die Wahrscheinlichkeitsverteilung einer Zufallsvariable wie z.B. über den Mittelwert oder die Streuung einer Normalverteilung.

### Statistischer Test

Ein statistischer Test ist eine Regel, nach der aufgrund einer beobachteten Zufallsvariable (Teststatistik) entschieden wird, ob eine Hypothese  $H_0$  abgelehnt wird oder nicht.

# Teil 1: Das Einfache Lineare Modell

## 1–5 Modellauswahl

Hypothesentest für  $\beta_i$

$$\hat{\beta}_i \sim F_{\text{NV}} \left( \beta_i; \sigma_{\hat{\beta}_i}^2 = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right)$$

Teststatistik:

$$t = \frac{\hat{\beta}_i - \beta_i}{\sigma_{\hat{\beta}_i}}$$

# Teil 1: Das Einfache Lineare Modell

## 1–5 Modellauswahl

### Hypothesentest für $\beta_i$ :

Teststatistik:

$$t = \frac{\hat{\beta}_i - \beta_i}{\hat{\sigma}_{\hat{\beta}_i}} \text{ mit } \hat{\sigma}_{\hat{\beta}_i} = \sqrt{\frac{\sum_{i=1}^n \hat{u}_i^2}{(T - k - 1)}}$$

$t \sim F_t(T - k)$  mit  $k$ : Anzahl der zu schätzenden Parameter

# Teil 1: Das Einfache Lineare Modell

## 1–6 Das multivariate Lineare Modell

### 1–6.1 Exkurs: Rechnen mit Matrizen: Invertieren einer Matrix (Gauss-Jordan-Algorithmus)

Die Inverse einer Matrix ist diejenige Matrix, die multipliziert mit der ursprünglichen Matrix die Einheitsmatrix ergibt.

$$M \cdot M^{-1} = I$$

# Teil 1: Das Einfache Lineare Modell

## 1–6 Das multivariate Lineare Modell

### 1–6.1 Exkurs: Rechnen mit Matrizen: Multiplizieren von Matrizen

- Das Element  $x_{ij}$  einer Matrix, die das Produkt aus zwei Matrizen darstellt, ergibt sich durch das Produkt der  $i$ -ten Zeile der ersten Matrix mit der  $j$ -ten Spalte der zweiten.
- Das Multiplizieren ist nicht kommutativ, d.h.  $A \cdot B \neq B \cdot A$

# Teil 1: Das Einfache Lineare Modell

## 1–6 Das multivariate Lineare Modell

1–6.1 Exkurs: Rechnen mit Matrizen: Transponieren einer Matrix (Gauss-Jordan-Algorithmus)

Vertausche von Zeilen und Spalten:

Sei  $M_{i \times j} \Rightarrow M_{j \times i}$

# Teil 1: Das Einfache Lineare Modell

## 1–6 Das multivariate Lineare Modell

1–6.1 Exkurs: Rechnen mit Matrizen: Berechnen der Determinante einer Matrix (Jägerzaunmethode)

Determinante: Skalar einer quadratischen Matrix

$$\det(M) = |M|$$

# Teil 1: Das Einfache Lineare Modell

## 1–6 Das multivariate Lineare Modell

### Modell

$$y = X\beta + u$$

$$\begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} = \begin{pmatrix} x_{11} = 1 & x_{12} & x_{13} & \dots & x_{k+11} \\ x_{21} = 1 & x_{22} & x_{23} & \dots & x_{2k} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_{n11} = 1 & x_{n2} & x_{n3} & \dots & x_{nk} \end{pmatrix} \cdot \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{pmatrix} + \begin{pmatrix} u_1 \\ u_2 \\ \vdots \\ u_n \end{pmatrix}$$

# Teil 1: Das Einfache Lineare Modell

## 1–6 Das multivariate Lineare Modell

### Schätzgleichungen

$$\hat{\beta} = (X'X)^{-1}X'y$$

in R:

$$\hat{\beta} = \text{solve}(t(X)\%*\%X)\%*\%X\%*\%y$$

# Teil 1: Das Einfache Lineare Modell

## 1–6 Das multivariate Lineare Modell

### Schätzung von $\sigma^2$ und dem Bestimmtheitsmaß $R^2$

Aus dem KQ-Residuen  $\hat{u}_t$  kann  $\sigma^2$  geschätzt werden:

$$\hat{\sigma}_u^2 = \frac{\hat{u}'\hat{u}}{n - (k + 1)}$$

# Teil 1: Das Einfache Lineare Modell

## 1–6 Das Multivariate Lineare Modell

Verteilung der Teststatistik  $F\beta$  bei unbekanntem  $\sigma^2$

$$F\beta = \frac{(\hat{\beta} - \beta^0)' X' X (\hat{\beta} - \beta^0)}{\hat{u}' \hat{u}} \cdot \frac{n - k - 1}{k + 1} \sim F_F(k + 1, n - k - 1)$$

# Teil 1: Das Einfache Lineare Modell

## 1–7 Das Multivariate Lineare Modell

Schätzung des bedingten Erwartungswertes der abhängigen Variablen für den Zeitpunkt  $F = n + 1$

im bivariaten Modell:

$$\begin{aligned} E(y_F | x_F) &= \beta_0 + \beta_1 \cdot x_F \\ \hat{y}_F &= \hat{\beta}_0 + \hat{\beta}_1 \cdot \hat{x}_F \end{aligned}$$

im multivariaten Modell:

$$\begin{aligned} E(y_F | x_F) &= x_F \beta \\ \hat{y}_F &= x_F \hat{\beta} \end{aligned}$$

# Teil 1: Das Einfache Lineare Modell

## 1–7 Prognose

### Ursachen für Prognosefehler

- Lineare Modell ist grundsätzlich richtig, aber
  - Falsche Prognose von  $\hat{x}_F$  in der ex ante-Prognose
  - Störgrößenfehler:  $u_F$  hat nicht den Mittelwert 0 angenommen
  - Stichprobenfehler:  $\hat{\beta} \neq \beta$
- Lineare Modell ist falsch
  - es gilt zwar im Schätzzeitraum, nicht aber im Prognosefall
  - ist fehlseparametrisiert (gilt also in keinem Zeitraum)

# Teil 1: Das Einfache Lineare Modell

## 1–7 Prognose

Prognosefehler:  $\hat{y}_F - y_F$

$$E(\hat{y}_F - y_F) = 0$$

$$\text{Var}(\hat{y}_F - y_F) = \sigma_P^2 = \hat{\sigma}^2 \cdot \left( 1 + \frac{1}{n} + \frac{(x_F - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right)$$

# Teil 1: Das Einfache Lineare Modell

## 1–7 Prognose

### Berechnung des Prognoseintervalls – Vorgehensweise

- ① Schätzung von  $\hat{\sigma}_P^2$
- ② Festlegen des Signifikanzniveaus
- ③ Standardisierung des Prognosefehlers
- ④ Ermittlung des Wertes der  $t$ -Verteilung
- ⑤ Berechnung der Intervallgrenzen

# Teil 1: Das Einfache Lineare Modell

## 1–7 Prognose

### Final Prediction Error

$$\begin{aligned} \text{FPE} &= E[(\hat{y}_F - y_F)(\hat{y}_F - y_F)'] \\ &\approx \sigma^2 \cdot \frac{\hat{u}' \hat{u}}{n-k} \cdot \frac{n+k}{n} \end{aligned}$$

# Teil 1: Das Einfache Lineare Modell

## 1–7 Prognose

### Alternative konsistente Gütekriterien

- Schwarzkriterium:

Wähle das Modell mit minimalem SBIC =  $\ln \sigma_{R^2} + \frac{k \cdot \ln n}{n}$

- Hannan-Quinn-Kriterium:

Wähle das Modell mit minimalem HQ =  $\ln \sigma_{R^2} + \frac{2k \cdot \ln(\ln n)}{n}$

# Teil 1: Das Einfache Lineare Modell

## 1–8 Test der Annahmen des Linearen Modells

### 1–8.1 Multikollinearität: Indikatoren für Multikollinearität

- Bestimmtheitsmaße der Hilfsregressionen:  $R_i^2$
- Variance Inflation Factors: VIF

# Teil 1: Das Einfache Lineare Modell

## 1–8 Test der Annahmen des Linearen Modells

### 1–8.1 Multikollinearität: Bestimmtheitsmaße der Hilfsregressionen: $R_i^2$

- Bestimmtheitsmaße der Hilfsregressionen aller Regressoren  $x_i$  auf alle übrigen Regressoren
- $R_i^2 = 1 - \frac{\text{Var}(\hat{\beta}_i^*)}{\text{Var}(\hat{\beta}_i)}$

# Teil 1: Das Einfache Lineare Modell

## 1–8 Test der Annahmen des Linearen Modells

### 1–8.1 Multikollinearität: VIF: Variance Inflation Factor

$$S_{x_1 x_1} = S_{x_{[1]} x_{[1]}} \cdot \underbrace{\frac{1}{(1 - R_{x_1 x_2}^2)}}_{\text{VIF}}$$

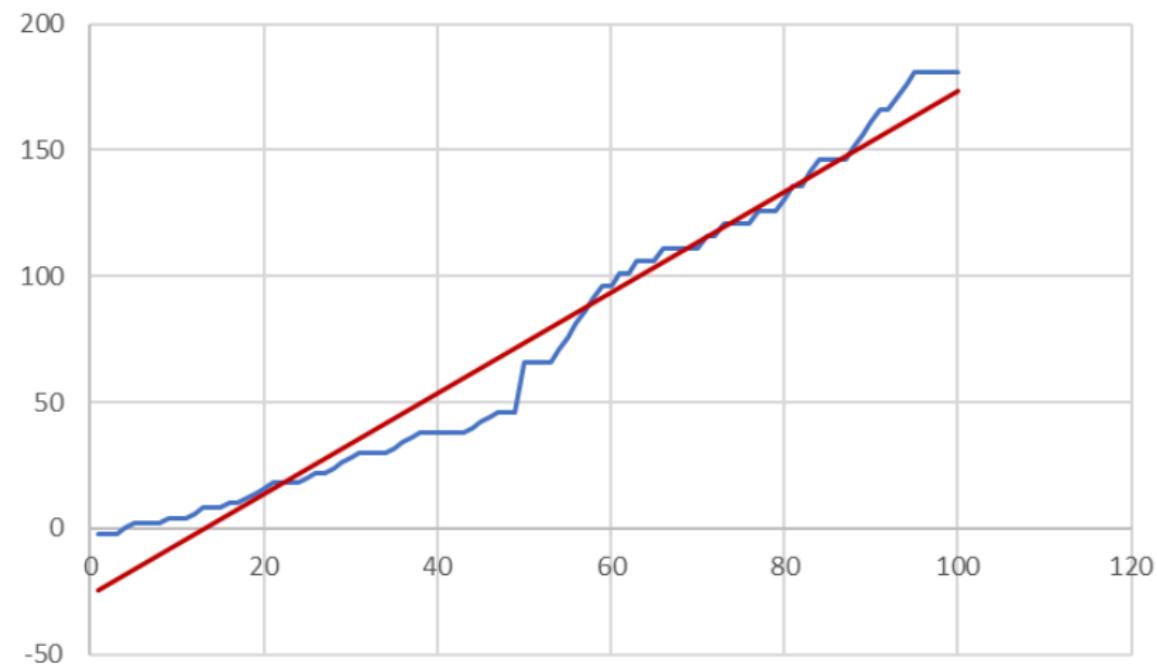
VIF = 0  $\leftrightarrow R_{x_1 x_2}^2 = 1$  : perfekte Multikollinearität

VIF = 1  $\leftrightarrow R_{x_1 x_2}^2 = 0$  : keine Multikollinearität

# Teil 1: Das Einfache Lineare Modell

## 1–8 Test der Annahmen des Linearen Modells

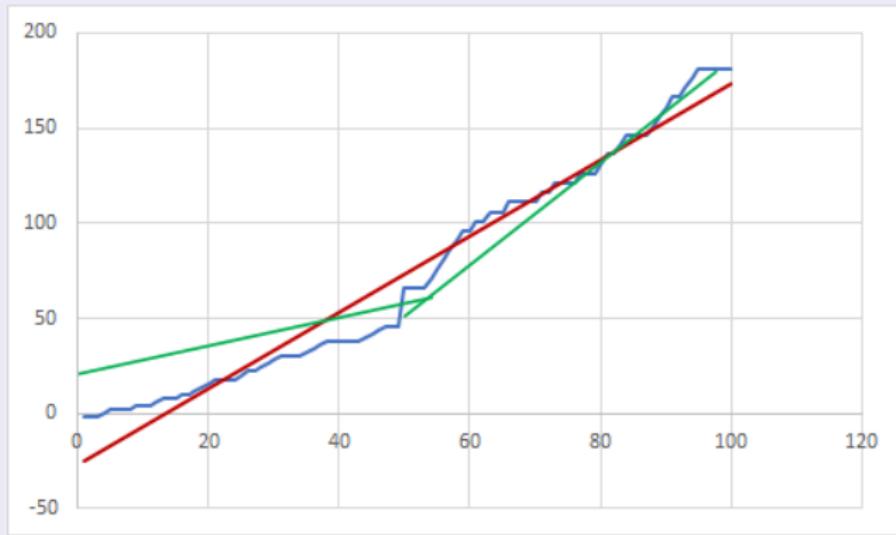
### 1–8.2 Strukturbrüche: Darstellung einer Zeitreihe mit Strukturbruch



# Teil 1: Das Einfache Lineare Modell

## 1–8 Test der Annahmen des Linearen Modells

### 1–8.2 Strukturbrüche: Darstellung einer Zeitreihe mit Strukturbruch



# Teil 1: Das Einfache Lineare Modell

## 1–8 Test der Annahmen des Linearen Modells

### 1–8.2 Strukturbrüche: Test auf Konstanz von $\beta$ anhand eines F-Tests

$$H_0 : \beta_1 = \beta_2 = \beta \Leftrightarrow H_1 : \beta_1 \neq \beta_2$$

#### Teststatistik des zugehörigen F-Tests

$$\begin{aligned} FS &= \frac{(\hat{y} - \hat{\bar{y}})'(\hat{y} - \hat{\bar{y}})}{\sigma^2(k+1)} \div \frac{\hat{u}'\hat{u}}{\sigma^2(T-2k-2)} \\ &= \frac{\hat{u}'\hat{u} - \hat{\bar{u}}'\hat{\bar{u}}}{\hat{u}'\hat{u}} \cdot \frac{T-2k-2}{k+1} \\ FS &\sim f_F(T-2k-2; k+1) \end{aligned}$$

# Teil 1: Das Einfache Lineare Modell

## 1–8 Test der Annahmen des Linearen Modells

1–8.2 Strukturbrüche: Test auf Konstanz von  $\beta$  anhand eines Chow-Tests

$$H_0 : \beta_1 = \beta \Leftrightarrow H_1 : \beta_1 \neq \beta$$

### Teststatistik des zugehörigen F-Tests

$$\begin{aligned} FS_{\text{Chow}} &= \frac{(\hat{\hat{y}} - \hat{y})'(\hat{\hat{y}} - \hat{y})}{\sigma^2(T - T_1)} \div \frac{\hat{\hat{u}}' \hat{\hat{u}}}{\sigma^2(T_1 - k - 1)} \\ &= \frac{\hat{\hat{u}}' \hat{\hat{u}} - \hat{\hat{u}}' \hat{\hat{u}}}{\hat{\hat{u}}' \hat{\hat{u}}} \cdot \frac{T_1 - k - 1}{T - t_1} \\ FS_{\text{Chow}} &\sim f_F(T - T_1; (T_1 - k - 1)) \end{aligned}$$

# Teil 1: Das Einfache Lineare Modell

## 1–8 Test der Annahmen des Linearen Modells

### 1–8.2 Strukturbrüche: CUSUM-Test

- $H_0$ : Modellparameter sind im gesamten Modellzeitraum konstant  
 $H_1$ : Modellparameter variieren
- Teststatistik:

$$CUSUM = \sum_{t=k+1}^T \hat{\sigma}_{pt} \sim F_{\text{NV}}(\mu = 0; \sigma^2 = T - k)$$

- Kritische Grenzen:

2 Geraden, einmal durch die Punkte  $(k, a_\alpha \sqrt{t-k})$  und  $(n, 3a_\alpha \sqrt{t-k})$   
bzw. auf der um die horizontale Achse gespiegelte Gerade.

für  $\alpha = 0,05 \Rightarrow a_\alpha = 0,948$

für  $\alpha = 0,01 \Rightarrow a_\alpha = 1,143$

Verwerfe  $H_0$ , wenn  $W_t$  außerhalb der Schranken

# Teil 1: Das Einfache Lineare Modell

## 1–8 Test der Annahmen des Linearen Modells

### 1–8.3 Homoskedastizität: Allgemeine Verwendung des F-Tests

$$H_0 : \sigma_1^2 = \sigma_2^2 = \sigma^2 \Leftrightarrow H_1 : \sigma_1^2 \neq \sigma_2^2$$

#### Teststatistik des zugehörigen F-Tests

$$\begin{aligned} FH &= \frac{\hat{\sigma}_1^2}{\hat{\sigma}_2^2} = \frac{\hat{u}'_1 \hat{u}_1}{\hat{u}'_2 \hat{u}_2} \cdot \frac{T_2 - k - 1}{T_1 - k - 1} \\ &\sim f_F((T_1 - k - 1); (T_2 - k - 1)) \end{aligned}$$

# Teil 1: Das Einfache Lineare Modell

## 1–8 Test der Annahmen des Linearen Modells

### 1–8.3 Homoskedastizität: Goldfeld-Quandt-Test

$$H_0 : \sigma_1^2 = \sigma_2^2 = \sigma^2 \Leftrightarrow H_1 : \sigma_1^2 < \sigma_2^2$$

Teststatistik:

$$\begin{aligned} GQ &= \frac{\hat{\sigma}_1^2}{\hat{\sigma}_2^2} = \frac{\hat{u}'_1 \hat{u}_1}{\hat{u}'_2 \hat{u}_2} \cdot \frac{T_2 - k}{T_1 - k} \\ &\sim f_F((T_1 - k); (T_2 - k)) \end{aligned}$$

# Teil 1: Das Einfache Lineare Modell

## 1–8 Test der Annahmen des Linearen Modells

### 1–8.3 Homoskedastizität: Breusch-Pagan-Lagrange-Multiplikator-Test

$$\sigma_t^2 = f(\delta_1 + \delta_2 Z_{t2} + \dots + \delta_p Z_{tp}) = f(Z_t' \delta)$$

$$H_0 : \delta_2 = \dots = \delta_p \Leftrightarrow H_1 : \delta_i \neq 0 \text{ für mind. ein } i$$

#### Testdurchführung

- Schätzung des Modells unter  $H_0$
- KQ-Residuen nutzen, um Schätzung unter  $H_1$  durchzuführen

$$f_t = \sigma_1^2 + \alpha \cdot Z_t + e_t \text{ mit } f_t = T \cdot \frac{\hat{u}_t^2}{\hat{u}' \hat{u}}$$

- Teststatistik:  $LM(H) = 0,5 \cdot \hat{f}' \hat{f} \sim f_{\chi^2}(r)$  mit  $r$ : Anzahl der unter  $H_0$  restriktiven Parameter

# Teil 1: Das Einfache Lineare Modell

## 1–8 Test der Annahmen des Linearen Modells

### 1–8.4 Autokorrelation: Definition Autokorrelation

Störgröße  $u_t$  ist mit den Störgrößen anderer Zeitpunkte korreliert.

#### Definition Autokorrelationskoeffizient

$$\varrho_\tau = \frac{E(u_t u_{t-\tau})}{E(u_t^2)}$$

#### Hypothesen beim Autokorrelationstest

$$H_0 : \varrho_\tau = 0 \quad \forall \tau \geq 1 \quad \leftrightarrow H_1 : \text{es liegt (irgend)eine Form der Autokorrelation}$$

# Teil 1: Das Einfache Lineare Modell

## 1–8 Test der Annahmen des Linearen Modells

### 1–8.4 Autokorrelation: Durbin-Watson-Test auf Autokorrelation erster Ordnung

$$H_0 : \varrho_1 = 0$$

#### Teststatistik

$$dw = \frac{\sum_{t=2}^n (\hat{u}_t - \hat{u}_{t-1})^2}{\sum_{t=1}^n \hat{u}_t^2} \simeq 2 \cdot (1 - \hat{\varrho}_1)$$

# Teil 1: Das Einfache Lineare Modell

## 1–8 Test der Annahmen des Linearen Modells

1–8.4 Autokorrelation: Breusch-Godfrey-Test: ein Lagrange-Multiplikator-Test

$$H_0 : \varphi_1 = \varphi_2 = \dots = \varphi_m = 0$$

### Teststatistik

$$LM(A) = n \cdot R_{\hat{u}}^2 \sim F_{\chi^2}(\nu = m)$$

# Teil 1: Das Einfache Lineare Modell

## 1–8 Test der Annahmen des Linearen Modells

### 1–8.4 Autokorrelation: Box-Pierce-Test

$$H_0 : \varrho_1 = \varrho_2 = \dots = \varrho_m = 0$$

#### Teststatistik

$$\tilde{Q}(m) = T \cdot \sum_{k=1}^m \hat{\varrho}_k^2 \stackrel{d}{\sim} F_{\chi^2}(\nu = m) \text{ mit } \hat{\varrho}_k = \frac{\sum_{t=k+1}^n \hat{u}_t \hat{u}_{t-k}}{\sum_{t=1}^n \hat{u}_t^2}$$

Noch besser passt sich an endliche Stichproben die folgende Teststatistik an:

$$Q(m) = T \cdot (T + 2) \cdot \sum_{k=1}^m \frac{\hat{\varrho}_k^2}{T - k} \stackrel{d}{\sim} F_{\chi^2}(\nu = m)$$

# Teil 1: Das Einfache Lineare Modell

## 1–8 Test der Annahmen des Linearen Modells

### 1–8.5 Normalverteilung: Jarque-Bera-Test

Test der dritten und vierten Momente der Normalverteilung:

$$H_0 : \mu_3 = 0 \text{ und } \mu_4 = 3\sigma^4 \text{ bzw. } H_0 : \mu_3/\sigma^3 = 0 \text{ und } \mu_4/\sigma^4 - 3 = 0$$

**Teststatistik:**

$$Z_1 = \frac{1}{T} \frac{\left( \sum_t \frac{\hat{u}_t^3}{\hat{\sigma}^3} \right)^2}{6} \quad Z_2 = \frac{1}{T} \frac{\left( \sum_t \frac{\hat{u}_t^4}{\hat{\sigma}^4} - 3 \right)^2}{24}$$

$$Z_1 + Z_2 \stackrel{d}{\sim} F_{\chi^2}(\nu = 2)$$