

Seminar Data Science & AI

Frühwarnsystems für Unternehmenskrisen

Submission Date:

20. November 2025

Submitted by:

Reebal Sami 106441

Supervisor:

Prof. Dr. Franziska Bönte

Fachhochschule Wedel

Feldstraße 143

22880 Wedel

Phone: 04103 - 8048 - 35

E-Mail: franziska.boente@fh-wedel.de

Contents

List of Figures	V
List of Tables	VI
1 Einleitung	1
2 Theoretischer Hintergrund und Stand der Forschung	2
3 Daten und Methodik: Foundation-Phase	3
3.1 Datenquelle und Struktur	3
3.1.1 Umfang und Grundstruktur	4
3.1.2 Datenstruktur: Wiederholte Querschnitte	4
3.1.3 Zielvariable und Klassenverteilung	6
3.1.4 Zeitliche Abdeckung	6
3.2 Finanzkennzahlen und Kategorisierung	6
3.2.1 Kategorisierung nach Kennzahlendimensionen	6
3.2.2 Mathematische Struktur und Redundanzen	7
3.2.3 Implikationen für die Modellierung	8
3.2.4 Ökonomische Interpretierbarkeit	8
3.3 Zeitliche Struktur und Insolvenztrend	9
3.3.1 Insolvenzrate nach Prognosehorizont	9
3.3.2 Ökonomische Interpretation	10
3.3.3 Heterogenität der Prognosehorizonte	10
3.3.4 Implikationen für die Modellierungsstrategie	11
3.4 Datenqualität und identifizierte Probleme	11
3.4.1 Fehlende Werte: Umfang und Muster	12
3.4.2 Duplikate: Natur und Umgang	12
3.4.3 Ausreißer: Systematische Identifikation	13
3.4.4 Varianz: Konstante und quasi-konstante Features	14
3.4.5 Horizontspezifische Datenqualitätsanalyse	14
3.4.6 Zusammenfassung der Datenqualitätsprobleme	16
3.4.7 Methodische Reflexion	16
4 Datenaufbereitung: Data Preparation	17
4.1 Entfernung exakter Duplikate	17
4.1.1 Methodik der Duplikat-Identifikation	17
4.1.2 Umgang mit Unsicherheit	18
4.1.3 Implementierung und Timing	18
4.1.4 Ergebnis und Auswirkungen	18
4.1.5 Horizontspezifische Verteilung der Duplikate	19
4.1.6 Methodische Reflexion	19
4.2 Winsorisierung extremer Werte	20
4.2.1 Methodenwahl: Winsorisierung vs. Alternativen	20
4.2.2 Implementierung: 1./99. Perzentil	20

4.2.3	Ergebnis und Auswirkungen	21
4.2.4	Validierung: Erhalt der Stichprobengröße	21
4.2.5	Timing im Preprocessing-Ablauf	21
4.2.6	Methodische Reflexion und Limitationen	22
4.3	Imputation fehlender Werte	22
4.3.1	Methodenwahl: MICE mit BayesianRidge	23
4.3.2	Direkte Ratio-Imputation (JAV)	24
4.3.3	Hyperparameter und Implementierungsdetails	24
4.3.4	Qualitätsbewertung der Imputation	25
4.3.5	Sonderfall A37: Umgang mit hoher Missingness	26
4.3.6	Verifikation der Imputation	27
4.3.7	Methodische Reflexion	27
4.4	Zusammenfassung der Data Preparation-Phase	27
4.4.1	Erreichte Datenqualität	28
4.4.2	Methodische Stärken	28
4.4.3	Dokumentierte Limitationen	29
4.4.4	Bereitschaft für nachfolgende Phasen	29
4.4.5	Kritische Würdigung	29
5	Explorative Datenanalyse	31
5.1	Verteilungsanalyse der Finanzkennzahlen	31
5.1.1	Stichprobengrößen und Klassenbalance	31
5.1.2	Schiefe und Verteilungseigenschaften	32
5.2	Univariate Signifikanztests mit FDR-Kontrolle	32
5.2.1	Methodologie	33
5.2.2	Ergebnisse über alle Horizonte	34
5.2.3	Beispielhafte Top-Features (Horizont H1)	34
5.3	Korrelationsanalyse und ökonomische Validierung	35
5.3.1	Ausmaß der Multikollinearität	35
5.3.2	Ökonomische Plausibilitätsvalidierung	37
5.4	Zusammenfassung der explorativen Erkenntnisse	38
6	Multikollinearitätskontrolle	39
6.1	Methodologie: Variance Inflation Factor	39
6.1.1	Definition und Interpretation	39
6.1.2	Schwellenwert-Begründung	40
6.1.3	Iterativer Pruning-Algorithmus	40
6.2	Ergebnisse der VIF-Analyse	41
6.2.1	Überblick über alle Horizonte	41
6.2.2	Detaillierte Analyse: Horizont H1	42
6.2.3	Horizont-übergreifende Muster	43
6.3	Validierung und methodische Reflexion	43
6.3.1	Konsistenz mit Korrelationsanalyse	43
6.3.2	Finales Feature-Set: Ökonomische Interpretierbarkeit	44
6.3.3	Methodische Limitationen	44
6.4	Zusammenfassung und Konsequenzen	45

7	Feature Selection	46
7.1	Ziel und Einordnung	46
7.2	Methodischer Rahmen und Gütekriterien	46
7.3	Vorgehensmodell	46
7.3.1	Filtermethoden	46
7.3.2	Wrappermethoden	47
7.3.3	Eingebettete Methoden	47
7.4	Vom einfachen zum verschachtelten Ansatz	47
7.5	Stabilität der Auswahl	47
7.6	Konsensbildung unter Guardrails	48
7.7	Ergebnisse für H1 (verschachtelte Analyse)	48
7.8	Aggregierte Übersichten	50
7.9	Diagnostik und Robustheit	52
8	Modellierung und Evaluation	54
8.1	Modellarchitekturen	54
8.1.1	Baseline: Logistische Regression	54
8.1.2	Random Forest	54
8.1.3	Gradient Boosting und weitere Modelle	54
8.2	Hyperparameter-Tuning	55
8.2.1	Cross-Validation	55
8.2.2	Horizontspezifisches Tuning	55
8.3	Behandlung der Klassenimbalance	55
8.4	Ergebnisse	56
9	Limitations and Future Work	59
9.1	Unfinished Tasks (Computational Constraints)	59
9.2	Methodological Enhancements	59
9.3	Cross-Dataset Generalization	60
9.4	Runtime Engineering	60
9.5	Documented Limitations	60
10	Conclusion	61
	Bibliography	62

List of Figures

3.1	Entwicklung der Insolvenzrate über Prognosehorizonte	10
4.1	Imputationsqualität: Verteilung der Quality Scores und Diagnostik	26
5.1	Schiefe-Übersicht (H1): Anteile extremer Schiefe je Kennzahl	32
5.2	Korrelationsheatmap (H1): Pearson-Korrelationen der 64 Kennzahlen	36
6.1	Entfernte Features pro Horizont (Schwellenwert: $VIF > 10$)	41
7.1	Konsens-Featureanzahl und AUC-Retention je Horizont (Basis: VIF-Featuremenge)	51
8.1	Bestes Modell und ROC-AUC je Horizont	57

List of Tables

3.1	Verteilung der Beobachtungen nach Prognosehorizont	4
3.2	Kategorisierung der 64 Finanzkennzahlen	7
3.3	Insolvenzrate nach Prognosehorizont	9
3.4	Kennzahlen mit den höchsten Anteilen fehlender Werte	12
3.5	Kennzahlen mit den höchsten Ausreißeranteilen	14
3.6	Ausreißerraten nach Prognosehorizont	15
3.7	Übersicht Datenqualitätsprobleme und Behandlung	16
4.1	Ergebnis der Duplikat-Entfernung	19
4.2	Ergebnis der Winsorisierung	21
4.3	Ergebnis der Missing Value Imputation	25
4.4	Verifikation der Imputation	27
4.5	Übersicht Phase 01: Data Preparation	28
5.1	Stichprobengrößen und Insolvenzraten nach Horizont	32
5.2	Univariate Testergebnisse nach Horizont	34
5.3	Multikollinearität nach Horizont	35
5.4	Ökonomische Plausibilität der Feature-Insolvenz-Korrelationen (H1)	37
6.1	Zusammenfassung der VIF-basierten Multikollinearitätskontrolle	41
6.2	In H1 entfernte Features (Top 10 nach VIF bei Entfernung)	42
7.1	Vergleich H1: Alter vs. verschachtelter Ansatz	49
7.2	Methodenvergleich (ROC-AUC)	51
7.3	Stabilität über Falten (Nogueira)	52
7.4	Konsens und Guardrails	52
8.1	Modellgüte pro Horizont (beste ROC-AUC und PR-AUC)	56
8.2	Baseline vs. Extra/Ensemble je Horizont (ROC-AUC)	56
8.3	Modellvergleich (ROC-AUC) – alle Modelle je Horizont (Phase 05, Base + Extra)	56

1 Einleitung

Noch bevor eine Insolvenz offiziell wird, beginnt sie oft leise: Liquidität versickert, Margen erodieren, Bilanzrelationen kippen. Für Banken, Lieferanten und Aufsichtsinstanzen ist entscheidend, diese Signale frühzeitig und belastbar zu erkennen. Klassische Kennzahlensysteme und Scoring-Modelle haben hier Pionierarbeit geleistet, doch sie stoßen bei komplexen Mustern, kleinen Stichproben und Klassenungleichgewichten an Grenzen (Altman, 1968; Barboza et al., 2017; Saito and Rehmsmeier, 2015).

Diese Arbeit verfolgt ein klares Ziel: ein Frühwarnsystem, das präzise genug für die Praxis ist und zugleich nüchtern, nachvollziehbar und leicht zu pflegen bleibt. Wir setzen auf bekannte Bilanzkennzahlen und formen daraus ein kleines, tragfähiges Set. Die Modelle werden über mehrere Vorlaufhorizonte hinweg fair geprüft und miteinander verglichen: eine gut interpretierbare logistische Regression als Ausgangspunkt und robuste Baumverfahren als Gegenstück. Wichtig ist die Anwendbarkeit im Alltag: wenige Größen, klare Auswertung, belastbare Aussagen.

Die zentrale Botschaft ist einfach: Mit schlanken, stabilen Kennzahlensets lassen sich solide Vorhersagen erzielen. Über weite Strecken erweist sich der Random Forest als stärkste Wahl, während auf kurzer Frist ein leichtes Ensemble knapp vorn liegt (Kap. 7–8). Der Beitrag dieser Arbeit ist damit ein transparentes Vorgehen, das sich ohne große Hürden in bestehende Risikoprozesse integrieren lässt. Kapitel 2 skizziert den Forschungsstand, Kapitel 3–6 die Datenbasis und Aufbereitung, Kapitel 7–8 die Auswahl und den Modellvergleich; Kapitel 9 zeigt konkrete nächste Schritte.

2 Theoretischer Hintergrund und Stand der Forschung

Frühe Ansätze der Insolvenzprognose beruhen auf Kennzahlen und Linearkombinationen. Beavers univariate Tests identifizierten bereits in den 1960er-Jahren Trennschärfe in Liquiditäts- und Ertragskennzahlen, während der Z-Score nach Altman (1968) eine multivariate Diskriminanzanalyse etablierte. Diese Klassiker wirken bis heute fort, stoßen aber bei Heterogenität, Nichtlinearität und zeitlicher Verschiebung der Signale an Grenzen.

Mit der Ausbreitung datengetriebener Methoden erweiterte sich das Spektrum auf Logit-Modelle, Boosting/Bagging-Ansätze und tiefe Netze. Meta-Analysen und Vergleichsarbeiten zeigen, dass moderne ML-Methoden—insbesondere Ensemble-Verfahren—klassische Spezifikationen häufig übertreffen, wenn Vorverarbeitung, Regularisierung und Validierung sorgfältig ausgelegt sind (Barboza et al., 2017; Sun et al., 2024; Hastie et al., 2009).

Die ökonomische Intuition bleibt jedoch zentral: Kennzahlen zu Profitabilität, Liquidität, Leverage, Effizienz und Aktivität bilden die klassische Grundlage der Früherkennung. Gleichzeitig erfordern Verhältniskennzahlen besondere Sorgfalt in der Aufbereitung (Winsorisierung/Imputation) und in der Modellierung (Robustheit gegenüber Ausreißern und Verzerrungen) (Hippel, 2013; Buuren, 2018). Multikollinearität ist weit verbreitet und verzerrt Koeffizienten und Unsicherheiten, weshalb VIF-Grenzen als praktikable Daumenregel genutzt werden—unter Beachtung der methodischen Einschränkungen (O’Brien, 2007; Penn State Eberly College of Science, 2024).

Methodisch ist die Validierung der entscheidende Hebel zur Vermeidung von Optimismus. Nested Cross-Validation reduziert Selektionsbias, der bei Hyperparameter- und Merkmalsauswahl sonst systematisch entsteht (Cawley and Talbot, 2010; Varma and Simon, 2006). Für unbalancierte Zielgrößen empfiehlt sich neben ROC-AUC die PR-AUC (Saito and Rehmsmeier, 2015). Zudem quantifiziert ein Stabilitätsmaß die Robustheit der Merkmalsauswahl über Folds (Nogueira et al., 2018), und die EPV-Regel dient als Guardrail gegen überparametrisierte Logit-Modelle (Peduzzi et al., 1996; Steyerberg, 2019). Schließlich mahnen Arbeiten zur Interpretierbarkeit, für risikorelevante Entscheidungen nach Möglichkeit transparente Modelle oder stabile, kleine Feature-Sets vorzuziehen (Rudin, 2019).

Vor diesem Hintergrund verbindet die vorliegende Arbeit klassische Bilanzlogik mit aktuellen ML-Praktiken: kontrollierte Multikollinearitätsreduktion, mehrgleisige Feature-Selektion mit Stabilität und Nested-CV, EPV-konforme Endmengen sowie ein fairer, stratifizierter Modellvergleich über mehrere Prognosehorizonte.

3 Daten und Methodik:

Foundation-Phase

Die Entwicklung eines robusten Frühwarnsystems für Unternehmenskrisen erfordert nicht nur leistungsfähige Algorithmen, sondern vor allem eine fundierte Datenbasis. Bevor maschinelle Lernverfahren ihre prädiktive Kraft entfalten können, bedarf es einer systematischen Analyse der Rohdaten – ein Schritt, der in der Praxis häufig unterschätzt wird, jedoch maßgeblich über Erfolg oder Misserfolg eines Projekts entscheidet (Goodfellow et al., 2016).

Dieses Kapitel dokumentiert die **Foundation-Phase (Phase 00)** des methodischen Ansatzes dieser Arbeit und charakterisiert die Datenbasis umfassend. Abschnitt 3.1 beschreibt Datenquelle und Struktur. Abschnitt 3.2 analysiert die Finanzkennzahlen und deren Kategorisierung. Abschnitt 3.3 untersucht die zeitliche Struktur und Insolvenztrends über die fünf Prognosehorizonte. Abschnitt 3.4 dokumentiert systematisch alle identifizierten Datenqualitätsprobleme.

Die nachfolgenden Kapitel beschreiben die weiteren Phasen der Pipeline: **Phase 01 – Datenaufbereitung** (Kapitel 4) behandelt Duplikate, Ausreißer und fehlende Werte. **Phase 02 – Explorative Datenanalyse** (Kapitel 5) untersucht Verteilungen, univariate Tests und Korrelationsmuster. **Phase 03 – Multikollinearitätskontrolle** (Kapitel 6) reduziert mittels VIF-Analyse redundante Features. **Phase 04 – Feature Selection** (Kapitel 7) selektiert prädiktiv relevante Merkmale unter ökonometrischen Schutzschranken. Schließlich beschreibt **Phase 05 – Modellierung** (Kapitel 8) die eingesetzten Machine-Learning-Verfahren und deren Evaluation.

3.1 Datenquelle und Struktur

Der empirischen Analyse liegt der Datensatz *Polish Companies Bankruptcy* aus dem **UCI Machine Learning Repository** zugrunde (Zięba et al., 2016). Die Daten stammen aus der Datenbank Emerging Markets Information Service (EMIS) und wurden von Zięba, Tomczak und Tomczak (2016) für Ensemble-Klassifikatoren zusammengestellt. Der Datensatz ist frei verfügbar über das UCI Repository¹ sowie Kaggle und umfasst Finanzkennzahlen polnischer Unternehmen aus dem Zeitraum 2000 bis 2013.

¹<https://archive.ics.uci.edu/dataset/365/>

3.1.1 Umfang und Grundstruktur

Die Datenbasis besteht aus **43.405 Beobachtungen**, die jeweils ein Unternehmen zu einem bestimmten Zeitpunkt und für einen spezifischen Prognosehorizont repräsentieren. Für jede Beobachtung sind **64 Finanzkennzahlen** (bezeichnet als A1 bis A64) sowie eine binäre Zielvariable verfügbar, die angibt, ob das Unternehmen innerhalb des jeweiligen Prognosehorizonts insolvent wurde (1) oder nicht (0).

Ein Alleinstellungsmerkmal dieses Datensatzes ist die Berücksichtigung **fünf unterschiedlicher Prognosehorizonte** (H1 bis H5), die Vorhersagezeiträume von einem bis fünf Jahren abbilden. Tabelle 3.1 zeigt die Verteilung der Beobachtungen über die Horizonte.

Table 3.1: Verteilung der Beobachtungen nach Prognosehorizont

Horizont	Beschreibung	N	Anteil (%)
H1	1 Jahr	7.027	16,2
H2	2 Jahre	10.173	23,4
H3	3 Jahre	10.503	24,2
H4	4 Jahre	9.792	22,6
H5	5 Jahre	5.910	13,6
Gesamt		43.405	100,0

Quelle: Eigene Darstellung basierend auf Script 00a_polish_dataset_overview.py

Die ungleiche Verteilung der Beobachtungen über die Horizonte – mit einem deutlichen Schwerpunkt auf H2 und H3 – reflektiert die Datenverfügbarkeit im Ursprungsdatensatz. Horizont H5 weist mit 5.910 Beobachtungen die geringste Fallzahl auf, was bei der späteren Modellierung zu beachten ist.

3.1.2 Datenstruktur: Wiederholte Querschnitte

Eine kritische Eigenschaft des Datensatzes ergibt sich aus dem Fehlen eines Unternehmensidentifikators. Die Daten enthalten keine Variable, die es ermöglichen würde, ein bestimmtes Unternehmen über verschiedene Zeitpunkte oder Horizonte hinweg zu verfolgen. Dies hat weitreichende methodische Konsequenzen:

Implikation: Bei den vorliegenden Daten handelt es sich nicht um Paneldaten, sondern um **wiederholte Querschnitte** (repeated cross-sections). Jede Beobachtung ist als unabhängig zu betrachten. Folglich sind Methoden, die auf einer zeitlichen Verfolgung derselben Einheiten basieren (z. B. Fixed-Effects- oder Random-Effects-Modelle), nicht anwendbar (Wooldridge, 2010).

Besonderheit der Horizont-Struktur Ein methodisch wichtiges Merkmal des Datensatzes ergibt sich aus der spezifischen Konstruktion der Prognosehorizonte. Die Bezeichnungen H1 bis H5 suggerieren zunächst, dass sie unterschiedlich weit in die Zukunft blicken. Tatsächlich jedoch repräsentieren die fünf Horizonte **unterschiedliche Beobachtungszeitpunkte desselben Prognosezeitraums**.

Zeitliche Struktur der Horizonte:

- **H1:** Finanzdaten aus Jahr 1 → Insolvenzstatus in Jahr 6 (5 Jahre Vorlaufzeit)
- **H2:** Finanzdaten aus Jahr 2 → Insolvenzstatus in Jahr 6 (4 Jahre Vorlaufzeit)
- **H3:** Finanzdaten aus Jahr 3 → Insolvenzstatus in Jahr 6 (3 Jahre Vorlaufzeit)
- **H4:** Finanzdaten aus Jahr 4 → Insolvenzstatus in Jahr 6 (2 Jahre Vorlaufzeit)
- **H5:** Finanzdaten aus Jahr 5 → Insolvenzstatus in Jahr 6 (1 Jahr Vorlaufzeit)

Alle Horizonte prognostizieren damit die Insolvenz zum **selben Zieljahr**, jedoch basierend auf Finanzdaten aus unterschiedlich weit zurückliegenden Jahren. Ein konkretes Beispiel verdeutlicht diese Struktur: Angenommen, ein Unternehmen geht im Jahr 2010 bankrott. Dieses Unternehmen könnte in allen fünf Horizonten erscheinen – in H1 mit Finanzdaten von 2005, in H2 mit Daten von 2006, bis hin zu H5 mit Daten von 2009. Die fehlende Unternehmens-ID verhindert jedoch die direkte Identifikation solcher Überlappungen.

Implikationen dieser Struktur:

1. **Pseudo-Replikation:** Es ist wahrscheinlich, dass identische Unternehmen in mehreren Horizonten auftreten. Dies könnte zur sogenannten Pseudo-Replikation führen, bei der statistisch unabhängige Beobachtungen angenommen werden, obwohl tatsächlich Abhängigkeiten bestehen. Die horizontspezifische Modellierung (siehe Kapitel 8) minimiert dieses Problem, da jedes Modell ausschließlich einen Horizont verwendet.
2. **Unterschiedliche Prädiktionsmuster:** In frühen Jahren (H1, H2) können finanzielle Schwierigkeiten noch latent sein, während sie in späten Jahren (H4, H5) bereits manifest werden. Dies erklärt die unterschiedlichen Insolvenzraten über Horizonte hinweg (siehe Abschnitt 3.3) und rechtfertigt die Entwicklung separater Modelle je Horizont.
3. **Validierungsstrategie:** Die zeitliche Struktur determiniert die Wahl geeigneter Validierungsstrategien. Ein zeitbasierter Holdout auf Unternehmensebene ist nicht möglich, daher wird auf eine horizontbasierte Aufteilung zurückgegriffen.

Diese Struktureigenschaft des Datensatzes ist für die Interpretation der späteren Modellergebnisse von zentraler Bedeutung: Die prognostische Aufgabe unterscheidet sich fundamental

zwischen den Horizonten – H1 muss sehr frühe Warnsignale identifizieren, während H5 bereits manifeste Krisensymptome erkennt.

3.1.3 Zielvariable und Klassenverteilung

Die Zielvariable y nimmt den Wert 1 an, wenn ein Unternehmen innerhalb des jeweiligen Prognosehorizonts insolvent wurde, andernfalls 0. Von den 43.405 Beobachtungen sind **2.091 als insolvent** klassifiziert, was einer Gesamtinsolvenzrate von **4,82 %** entspricht.

Diese ausgeprägte Klassenimbalance – typisch für Insolvenzdaten – stellt eine methodische Herausforderung dar: Naive Klassifikatoren könnten durch simples Vorhersagen der Mehrheitsklasse („nicht insolvent“) bereits eine Genauigkeit von 95,18 % erreichen, ohne tatsächlich prädiktive Muster zu erlernen. Strategien zur Handhabung dieser Imbalance werden in Kapitel 8 erörtert.

3.1.4 Zeitliche Abdeckung

Die Daten stammen aus dem Zeitraum 2000 bis 2013 und umfassen damit sowohl Phasen wirtschaftlicher Stabilität als auch die globale Finanzkrise von 2007/08. Diese zeitliche Heterogenität ist methodisch vorteilhaft, da Modelle so auf Daten aus unterschiedlichen Konjunkturzyklen trainiert werden können. Allerdings ist zu berücksichtigen, dass die Ergebnisse möglicherweise nicht ohne Weiteres auf aktuelle Verhältnisse übertragbar sind, da sich Rechnungslegungsstandards, regulatorische Rahmenbedingungen und Wirtschaftsstrukturen seither verändert haben könnten.

3.2 Finanzkennzahlen und Kategorisierung

Die 64 Finanzkennzahlen (A1 bis A64) bilden das Herzstück der Datenbasis. Im Gegensatz zu generischen Variablen handelt es sich hierbei um ökonomisch interpretierbare Ratios, die zentrale Dimensionen der Unternehmensperformance abbilden. Eine systematische Kategorisierung dieser Kennzahlen ist essentiell, um (1) ihre ökonomische Bedeutung zu verstehen, (2) erwartbare Korrelationsmuster zu antizipieren und (3) die spätere Interpretation von Modellergebnissen zu ermöglichen.

3.2.1 Kategorisierung nach Kennzahlendimensionen

Basierend auf der im Datensatz bereitgestellten Metadatei wurden die 64 Kennzahlen sechs funktionalen Kategorien zugeordnet. Tabelle 3.2 zeigt die Verteilung.

Table 3.2: Kategorisierung der 64 Finanzkennzahlen

Kategorie	Anzahl	Anteil (%)	Beispiele
Profitabilität	20	31,2	ROA, ROE, EBITDA-Marge, Nettogewinnmarge
Verschuldung	17	26,6	Debt-to-Equity, Leverage Ratio, Asset Coverage
Aktivität	15	23,4	Asset Turnover, Inventory Days, Receivables Days
Liquidität	10	15,6	Current Ratio, Quick Ratio, Cash Ratio
Größe	1	1,6	Logarithmus der Bilanzsumme
Sonstige	1	1,6	Spezialkennzahl
Gesamt	64	100,0	

Quelle: Eigene Darstellung basierend auf Script 00b_polish_feature_analysis.py

Profitabilitätskennzahlen bilden mit 20 Features (31,2 %) die größte Kategorie. Dies reflektiert die zentrale Rolle der Ertragskraft in der Insolvenzforschung: Bereits Altman (1968) identifizierte Profitabilitätsratios als wichtigste Prädiktoren im klassischen Z-Score-Modell (Altman, 1968). Bemerkenswert ist zudem der hohe Anteil an Verschuldungskennzahlen (17 Features, 26,6 %), was die Bedeutung der Kapitalstruktur für Insolvenzprognosen unterstreicht. Die hohe Anzahl ähnlicher Kennzahlen könnte zu Redundanzen führen, da viele Ratios ähnliche Aspekte der Unternehmensperformance messen.

3.2.2 Mathematische Struktur und Redundanzen

Eine detaillierte Analyse der Kennzahlenformeln – dokumentiert in der Metadatei – offenbart strukturelle Zusammenhänge, die zu erwartender Multikollinearität führen:

Inverse Kennzahlenpaare Ein besonders klarer Fall ist das Paar A17 und A2:

- A17: $\frac{\text{Aktiva}}{\text{Passiva}}$
- A2: $\frac{\text{Passiva}}{\text{Aktiva}}$

Diese beiden Kennzahlen sind mathematisch reziprok zueinander. Folglich weist ihre Korrelation zwangsläufig eine perfekte inverse Struktur auf ($r \approx -1$), was zu numerischer Instabilität in Regressionsmodellen führen kann.

Gemeinsame Nenner Ein weiteres Redundanzmuster ergibt sich aus der wiederholten Verwendung derselben Größe im Nenner. Die Analyse zeigt:

- 22 Kennzahlen verwenden **Umsatz** (Sales) im Nenner
- 18 Kennzahlen verwenden **Bilanzsumme** (Total Assets) im Nenner
- 12 Kennzahlen verwenden **Eigenkapital** (Equity) im Nenner

Kennzahlen mit identischem Nenner tendieren zu positiver Korrelation, da Schwankungen im Nenner alle betroffenen Ratios in dieselbe Richtung bewegen. Beispielsweise werden sämtliche umsatzbasierten Kennzahlen bei Umsatzrückgang mechanisch ansteigen, unabhängig vom Zähler.

Hierarchische Abhängigkeiten Einige Kennzahlen stehen in direkter rechnerischer Beziehung zueinander. Ein Beispiel:

$$\text{Operating Cycle} = \text{Inventory Days} + \text{Receivables Days}$$

Derartige additive Zusammenhänge erzeugen Multikollinearität, selbst wenn die einzelnen Komponenten nicht perfekt korreliert sind.

3.2.3 Implikationen für die Modellierung

Die identifizierten strukturellen Redundanzen haben weitreichende Konsequenzen:

1. **Multikollinearität:** Hohe Korrelationen zwischen Prädiktoren führen zu instabilen Regressionskoeffizienten und aufgeblähten Standardfehlern in linearen Modellen (Hastie et al., 2009).
2. **VIF-Analyse erforderlich:** In Phase 03 (Multikollinearitätsanalyse) wird der Variance Inflation Factor (VIF) für alle Kennzahlen berechnet. Kennzahlen mit $VIF > 10$ sind Kandidaten für Entfernung.
3. **Baum-basierte Modelle weniger betroffen:** Random Forests und XGBoost sind gegenüber Multikollinearität robuster als logistische Regression, da sie Variablen sequenziell betrachten.

3.2.4 Ökonomische Interpretierbarkeit

Trotz mathematischer Redundanzen besitzt jede Kennzahl eine eigenständige ökonomische Bedeutung. Beispiele:

- **A1 (Nettogewinn / Bilanzsumme):** Return on Assets – zentrale Profitabilitätskennzahl

- **A4 (Umlaufvermögen / kurzfr. Verbindlichkeiten):** Current Ratio – klassische Liquiditätskennzahl
- **A37 (Quick Assets / langfr. Verbindlichkeiten):** Misst Fähigkeit, langfristige Schulden aus liquiden Mitteln zu bedienen

Diese Interpretierbarkeit ist ein Vorteil gegenüber generischen Features und ermöglicht die Validierung von Modellergebnissen anhand betriebswirtschaftlicher Plausibilität.

3.3 Zeitliche Struktur und Insolvenztrend

Die Berücksichtigung multipler Prognosehorizonte (H1 bis H5) ist ein methodisches Alleinstellungsmerkmal dieses Datensatzes. Während die meisten Studien zur Insolvenzprognose sich auf einen fixen Zeithorizont beschränken – typischerweise ein Jahr (Altman, 1968) – ermöglicht dieser Datensatz die Untersuchung, ob und wie sich die Vorhersagbarkeit mit zunehmendem Zeitabstand verändert. Die folgende Analyse offenbart einen Befund, der zentrale Auswirkungen auf die Modellierungsstrategie hat.

3.3.1 Insolvenzrate nach Prognosehorizont

Tabelle 3.3 zeigt die Verteilung insolventer und nicht-insolventer Unternehmen über die fünf Horizonte.

Table 3.3: Insolvenzrate nach Prognosehorizont

Horizont	N	Insolvenzen	Rate (%)	Veränderung
H1 (1 Jahr)	7.027	271	3,86	Baseline
H2 (2 Jahre)	10.173	400	3,93	+1,8 %
H3 (3 Jahre)	10.503	495	4,71	+22,0 %
H4 (4 Jahre)	9.792	515	5,26	+36,3 %
H5 (5 Jahre)	5.910	410	6,94	+ 79,8 %

Quelle: Eigene Darstellung basierend auf Script 00c_polish_temporal_structure.py

Der augenfälligste Befund ist der **nahezu lineare Anstieg der Insolvenzrate** mit zunehmendem Prognosehorizont. Von H1 (3,86 %) zu H5 (6,94 %) ergibt sich eine Steigerung um fast 80 %. Dieser Trend ist in Abbildung 3.1 visualisiert.




Figure 3.1: Entwicklung der Insolvenzrate über Prognosehorizonte

Quelle: Eigene Darstellung basierend auf Script 00c_polish_temporal_structure.py

3.3.2 Ökonomische Interpretation

Der beobachtete Trend ist ökonomisch plausibel: Mit zunehmendem Zeitabstand steigt die Wahrscheinlichkeit, dass ein Unternehmen in finanzielle Schwierigkeiten gerät. Während ein Unternehmen mit robusten Fundamentaldaten die nächsten 12 Monate wahrscheinlich übersteht, erhöht sich über einen Fünf-Jahres-Zeitraum das Risiko externer Schocks (Konjunkturunbrüche, regulatorische Änderungen, disruptive Wettbewerber) oder interner Probleme (Managementfehler, verfehlte Investitionen).

Aus methodischer Sicht ist jedoch die **Größenordnung** der Veränderung entscheidend: Eine Verdoppelung der Insolvenzrate deutet darauf hin, dass H1- und H5-Daten aus unterschiedlichen Verteilungen stammen könnten.

3.3.3 Heterogenität der Prognosehorizonte

Die Standardabweichung der Insolvenzraten über die Horizonte beträgt 1,2 Prozentpunkte – bei einem Mittelwert von 4,82 % entspricht dies einem Variationskoeffizienten von 25 %. Diese Heterogenität ist nicht trivial und wirft die Frage auf, ob die fünf Horizonte als homogene Stichprobe behandelt werden sollten.

Literatureinbettung: Coats & Fant (1993) zeigen in ihrer Studie, dass die Beziehung zwischen Finanzkennzahlen und Insolvenzwahrscheinlichkeit über längere Zeithorizonte zunehmend nichtlinear wird (Coats and Fant, 1993). McLeay & Omar (2000) bestätigen diesen Befund und warnen vor der Annahme zeitlicher Homogenität bei Multi-Horizont-Daten (McLeay and Omar, 2000). Beide Studien argumentieren, dass unterschiedliche Zeithorizonte unterschiedliche prädiktive Dynamiken aufweisen können.

3.3.4 Implikationen für die Modellierungsstrategie

Die identifizierte Heterogenität hat weitreichende Konsequenzen für die methodische Vorgehensweise. Es stellen sich zwei zentrale Fragen:

Frage 1: Pooled Model oder horizontspezifische Modelle? Zwei Strategien sind denkbar:

- **Option A – Horizontspezifische Modelle:** Für jeden Horizont wird ein separates Modell trainiert (fünf Modelle insgesamt). Dies erlaubt horizontspezifische Koeffizienten und Feature Importance.
- **Option B – Pooled Model:** Ein gemeinsames Modell für alle Horizonte, wobei der Horizont als zusätzliches Feature einbezogen wird. Dies nutzt alle Daten, setzt jedoch voraus, dass Features alle Horizonte ähnlich beeinflussen.

Angesichts der 80-prozentigen Veränderung der Insolvenzrate erscheint Option A methodisch stringenter. Die Annahme, dass dieselben Kennzahlen mit denselben Gewichtungen sowohl 1-Jahres- als auch 5-Jahres-Insolvenzen vorhersagen, ist fraglich. Daher wurde für diese Arbeit **Option A gewählt**: In der Modellierungsphase (Kapitel 8) werden fünf separate Modelle entwickelt, eines je Horizont.

Frage 2: Train/Val/Test-Split Bei horizontspezifischen Modellen muss der Datensatz für jeden Horizont getrennt aufgeteilt werden. Ein zeitlicher Holdout (Train: H1–H3, Val: H4, Test: H5) ist nicht zielführend, da dies unterschiedliche Verteilungen vermischt. Stattdessen wird jeder Horizont einzeln in Train (60 %), Validation (20 %) und Test (20 %) aufgeteilt – unter Beibehaltung der Klassenverteilung durch stratifiziertes Sampling.

3.4 Datenqualität und identifizierte Probleme

Die Qualität der Rohdaten determiniert maßgeblich die Validität jeglicher darauf basierenden Analysen. Eine rigorose Qualitätsprüfung ist daher kein optionaler Zusatzschritt, sondern

methodische Notwendigkeit (Goodfellow et al., 2016). Die folgenden Abschnitte dokumentieren systematisch alle identifizierten Datenqualitätsprobleme – einschließlich getroffener Annahmen und deren Limitationen. Diese Transparenz ist essentiell für die kritische Einordnung der Ergebnisse.

3.4.1 Fehlende Werte: Umfang und Muster

Eine erste Überraschung der Datenanalyse: **Sämtliche 64 Finanzkennzahlen weisen fehlende Werte auf.** Die Ausprägung variiert jedoch erheblich. Tabelle 3.4 zeigt die fünf am stärksten betroffenen Kennzahlen.

Table 3.4: Kennzahlen mit den höchsten Anteilen fehlender Werte

Kennzahl	Bezeichnung	Fehlend (N)	Anteil (%)
A37	Quick Assets / LT Liabilities	18.984	43,74
A21	Umsatzwachstum	5.854	13,49
A27	Op. Profit / Fin. Expenses	2.764	6,37
A60	Inventory Turnover	2.152	4,96
A45	Net Profit / Inventory	2.147	4,95

Quelle: Eigene Darstellung basierend auf Script 00d_polish_data_quality.py

Kennzahl A37 (Quick Assets / langfristige Verbindlichkeiten) sticht mit 43,74 % fehlenden Werten hervor. Dieser hohe Anteil wirft die Frage auf, ob die Kennzahl überhaupt für Modellierung verwendbar ist. Zwei Ansätze wurden in Betracht gezogen:

1. **Entfernung der Kennzahl:** Sicher, aber mit Informationsverlust verbunden.
2. **Fortgeschrittene Imputation:** Erhalt der Kennzahl, jedoch mit Unsicherheit behaftet.

Die Entscheidung für Option 2 (Imputation) wird in Kapitel 4 detailliert begründet. Eine ergänzende horizontspezifische Analyse zeigt, dass die Missing-Rate von A37 zwischen H1 (41,0 %) und H5 (46,8 %) variiert – eine Schwankung von 5,8 Prozentpunkten, die im Kontext der Gesamtdatenqualität als moderat einzustufen ist und keine separaten Imputationsansätze je Horizont erfordert.

3.4.2 Duplikate: Natur und Umgang

Die Qualitätsprüfung identifizierte **401 exakte Duplikate** – definiert als Beobachtungen, bei denen *alle* 68 Variablen (64 Kennzahlen, Jahr, Horizont, Zielvariable, Insolvenzindikator) identisch sind. Dies entspricht 200 Paaren, bei denen jede Zeile exakt einmal dupliziert ist.

Problem der Verifikation Das Fehlen eines Unternehmensidentifikators verhindert eine abschließende Klärung der Duplikat-Natur. Zwei Szenarien sind denkbar:

- **Szenario A:** Identisches Unternehmen wurde versehentlich zweimal erfasst → Datenerfassungsfehler.
- **Szenario B:** Zwei unterschiedliche Unternehmen weisen zufällig identische Werte auf.

Szenario B erscheint statistisch äußerst unwahrscheinlich: Die Wahrscheinlichkeit, dass zwei Unternehmen in allen 64 (kontinuierlichen) Kennzahlen identische Werte aufweisen, ist infinitesimal gering. Eine Binomialrechnung unter Annahme vernünftiger Präzision (2 Dezimalstellen) liefert eine Wahrscheinlichkeit in der Größenordnung von 10^{-128} für ein einzelnes Paar.

Getroffene Annahme Angesichts dieser Überlegung wird **Szenario A** (Datenerfassungsfehler) als plausibler erachtet. Folglich wurden alle 401 Duplikate entfernt, wobei jeweils die erste Instanz beibehalten wurde.

Timing der Entfernung Kritisch ist, dass die Duplikat-Entfernung *vor* dem Train/Val/Test-Split erfolgt. Würden Duplikate über Train- und Test-Set verteilt, entstünde Data Leakage: Das Modell könnte auf einer Trainingsbeobachtung lernen und dieselbe Beobachtung im Test „vorhersagen“ – ein methodischer Kardinalfehler (Goodfellow et al., 2016).

Limitationen Diese Entscheidung bleibt eine **Annahme**. Ohne Unternehmensidentifikator ist keine definitive Verifikation möglich. Eine konservative Alternative wäre gewesen, beide Instanzen zu entfernen (Verlust von 802 Beobachtungen statt 401). Die gewählte Variante balanciert zwischen Vorsicht und Datenerhalt.

3.4.3 Ausreißer: Systematische Identifikation

Finanzielle Kennzahlen sind notorisch anfällig für Extremwerte – etwa durch Bilanzmanipulation, Sonderereignisse oder Messfehler. Eine systematische Ausreißeranalyse mittels der $3 \times \text{IQR}$ -Methode (Interquartilsabstand) ergab:

- **Alle 64 Kennzahlen** weisen Ausreißer auf.
- Der Anteil betroffener Beobachtungen variiert zwischen 0,07 % (A50) und 15,5 % (A27).
- Im Mittel sind 5,4 % der Werte je Kennzahl als Ausreißer klassifiziert (Median: 4,5 %).
- Nur 7 Kennzahlen (11 %) weisen Ausreißeranteile über 10 % auf.

Tabelle 3.5 zeigt die fünf am stärksten betroffenen Kennzahlen.

Table 3.5: Kennzahlen mit den höchsten Ausreißeranteilen

Kennzahl	Bezeichnung	Ausreißer (N)	Anteil (%)
A27	Op. Profit / Fin. Expenses	6.306	15,52
A6	Retained Earnings / Assets	6.525	15,04
A37	Quick Assets / LT Liabilities	2.919	11,95
A55	Working Capital	4.769	10,99
A45	Net Profit / Inventory	4.399	10,66

Quelle: Eigene Darstellung basierend auf Script 00d_polish_data_quality.py, 3×IQR-Methode

Behandlungsstrategie Extreme Werte wurden nicht entfernt, sondern mittels **Winsorisierung** behandelt: Werte unterhalb des 1. Perzentils werden auf das 1. Perzentil gesetzt, Werte oberhalb des 99. Perzentils auf das 99. Perzentil. Diese Methode dämpft Extremwerte ohne Informationsverlust durch Beobachtungsentfernung und ist in der empirischen Finanzforschung etabliert.

Timing Winsorisierung erfolgt *nach* Duplikat-Entfernung, aber *vor* Imputation. Dies ist methodisch wichtig: Würden Ausreißer erst nach Imputation behandelt, könnten sie die Imputationsstatistiken (Mediane, Mittelwerte) verzerren.

3.4.4 Varianz: Konstante und quasi-konstante Features

Ein weiteres potenzielles Problem sind Features mit geringer oder fehlender Varianz, da diese keine Information für Modellierung beisteuern. Die Analyse ergab jedoch:

- **Keine** Kennzahl weist Zero-Varianz auf.
- **Keine** Kennzahl weist extrem niedrige Varianz ($< 0,01$) auf.
- Alle 64 Kennzahlen haben substantielle Streuung.

Dieser Befund ist positiv: Alle Kennzahlen tragen potenziell Information bei und müssen nicht aus Varianzgründen entfernt werden.

3.4.5 Horizontspezifische Datenqualitätsanalyse

Eine zentrale methodische Frage ergibt sich aus der horizontspezifischen Modellierungsstrategie (siehe Kapitel 8): Unterscheidet sich die Datenqualität systematisch über die Prognosehorizonte H1 bis H5? Falls ja, könnte dies separate Preprocessing-Pipelines je Horizont erfordern.

Eine ergänzende Analyse untersuchte daher Ausreißerraten und fehlende Werte differenziert nach Horizonten.

Ausreißerraten über Horizonte Tabelle 3.6 zeigt die durchschnittlichen Ausreißerraten (3×IQR-Methode) für jeden Horizont, gemittelt über alle 64 Kennzahlen.

Table 3.6: Ausreißerraten nach Prognosehorizont

Horizont	Beobachtungen	Mittlere Ausreißerrate (%)	Maximum (%)
H1	7.027	4,14	12,84
H2	10.173	5,34	17,19
H3	10.503	5,76	19,85
H4	9.792	6,06	22,42
H5	5.910	5,15	15,64
Variation		1,92 Prozentpunkte (H1 vs. H4)	

Quelle: Eigene Darstellung basierend auf Script 00d_polish_data_quality.py, Schritt 5b

Befund: Die Ausreißerraten steigen tendenziell von H1 (4,14 %) zu H4 (6,06 %), fallen jedoch in H5 wieder leicht ab. Die Gesamtvariation beträgt 1,92 Prozentpunkte – ein verhältnismäßig geringer Unterschied. Dieser leichte Anstieg dürfte natürliche Datencharakteristika widerspiegeln (Unternehmen in späten Horizonten weisen mehr finanzielle Volatilität auf), nicht jedoch systematische Qualitätsdefizite.

Fehlende Werte über Horizonte (Beispiel A37) Als Illustration wurde die am stärksten betroffene Kennzahl A37 (Quick Assets / LT Liabilities) analysiert:

- H1: 41,0 % fehlend (2.883 von 7.027)
- H2: 43,9 % fehlend (4.466 von 10.173)
- H3: 44,2 % fehlend (4.642 von 10.503)
- H4: 44,3 % fehlend (4.338 von 9.792)
- H5: 46,8 % fehlend (2.766 von 5.910)

Die Variation beträgt 5,8 Prozentpunkte (H1 vs. H5). Während der Anstieg nicht vernachlässigbar ist, rechtfertigt er keine grundlegend unterschiedlichen Imputationsstrategien je Horizont.

Implikation für Preprocessing Die horizontspezifische Analyse zeigt **relative Stabilität der Datenqualität** über alle fünf Horizonte. Die Variation in Ausreißerraten (1,92 Prozentpunkte) und Missing-Raten (5,8 Prozentpunkte bei A37) ist moderat. Dies rechtfertigt

die Anwendung einer **einheitlichen Preprocessing-Pipeline** (Duplikatentfernung, Winsorisierung, Imputation) über alle Horizonte, gefolgt von horizontspezifischer Modellierung. Die beobachteten Unterschiede spiegeln natürliche Datencharakteristika wider und stellen keine methodische Herausforderung dar.

3.4.6 Zusammenfassung der Datenqualitätsprobleme

Tabelle 3.7 fasst die identifizierten Probleme und getroffenen Maßnahmen zusammen.

Table 3.7: Übersicht Datenqualitätsprobleme und Behandlung

Problem	Ausprägung	Maßnahme
Fehlende Werte	64/64 Kennzahlen betroffen; max. 43,7 % (A37)	Passive Imputation für Ratios (Kapitel 4)
Duplikate	401 exakte Duplikate	Entfernung vor Train/Test-Split
Ausreißer	64/64 Kennzahlen betroffen; 0,07 %–15,5 % je Feature (Mittel: 5,4 %)	Winsorisierung (1./99. Perzentil)
Varianz	Keine Zero- oder Low-Varianz-Features	Keine Aktion erforderlich

Quelle: Eigene Darstellung basierend auf Script 00d_polish_data_quality.py

3.4.7 Methodische Reflexion

Die Datenqualitätsanalyse offenbart ein realistisches Bild: Der Datensatz ist nicht „sauber“, sondern weist typische Probleme empirischer Finanzdaten auf. Die Herausforderung besteht darin, diese Probleme methodisch stringent zu behandeln, ohne dabei in zwei Extreme zu verfallen:

1. **Naives Ignorieren:** Probleme werden übersehen oder als „unproblematisch“ deklariert – führt zu verzerrten Ergebnissen.
2. **Überkonservatives Löschen:** Alle problematischen Beobachtungen/Features werden entfernt – führt zu massivem Informationsverlust.

Der gewählte Mittelweg – Imputation statt Löschung, Winsorisierung statt Entfernung, transparente Dokumentation von Annahmen – entspricht dem State of the Art in der empirischen Forschung und gewährleistet sowohl Datenerhalt als auch methodische Integrität.

Die detaillierte Umsetzung dieser Maßnahmen wird in Kapitel 4 (Datenaufbereitung) beschrieben.

4 Datenaufbereitung: Data Preparation

Die in Kapitel 3 dokumentierte Analyse der Datenbasis offenbarte drei zentrale Qualitätsprobleme: **401 exakte Duplikate**, **systematische Ausreißer in allen 64 Kennzahlen** sowie **41.037 fehlende Werte** über sämtliche Features. Während die Foundation-Phase diese Probleme identifiziert und quantifiziert hat, widmet sich die Data Preparation-Phase ihrer methodisch fundierten Behandlung.

Das vorliegende Kapitel dokumentiert die praktische Umsetzung evidenzbasierter Preprocessing-Strategien. Die Reihenfolge der Schritte ist dabei nicht arbiträr, sondern folgt methodischen Notwendigkeiten: Duplikate werden *zuerst* entfernt (Abschnitt 4.1), um Data Leakage zu vermeiden. Anschließend erfolgt die Behandlung von Ausreißern mittels Winsorisierung (Abschnitt 4.2), bevor fehlende Werte imputiert werden (Abschnitt 4.3). Diese Sequenz gewährleistet, dass Extremwerte die Imputationsstatistiken nicht verzerren (Goodfellow et al., 2016).

Das Ergebnis ist ein sauberer Datensatz mit 43.004 Beobachtungen und 0 % fehlenden Werten – bereit für die nachfolgende Modellierung. Alle implementierten Schritte sind über Python-Skripte vollständig reproduzierbar und dokumentiert.

4.1 Entfernung exakter Duplikate

Die in Abschnitt 3.4 identifizierten 401 exakten Duplikate stellen eine unmittelbare Bedrohung für die Validität jeglicher statistischer Inferenz dar. Würden diese Duplikate im Datensatz verbleiben, käme es zu einer künstlichen Übergewichtung bestimmter Beobachtungen – mit potenziell verzerrten Modellparametern als Folge. Die folgenden Abschnitte dokumentieren die methodische Behandlung dieses Problems.

4.1.1 Methodik der Duplikat-Identifikation

Als **exaktes Duplikat** wurde definiert: Eine Beobachtung, bei der *alle* 68 Variablen (64 Finanzkennzahlen, Jahr, Horizont, Zielvariable, Insolvenzindikator) mit mindestens einer anderen Beobachtung identisch sind. Diese strenge Definition minimiert das Risiko fälschlicher Entfernungen: Nur bei vollständiger Identität über alle Dimensionen wird ein Duplikat angenommen.

Die Identifikation erfolgte mittels der Pandas-Funktion `uplicated()`, die spaltenweise Übereinstimmung prüft. Es wurden **802 Zeilen als dupliziert** identifiziert, die sich zu **200 Paaren plus einer unpaarigen Zeile** gruppieren lassen. Dies deutet auf ein systematisches Datenerfassungsproblem hin: Jede Beobachtung wurde im Mittel exakt einmal versehentlich dupliziert.

4.1.2 Umgang mit Unsicherheit

Das Fehlen eines Unternehmensidentifikators verhindert die definitive Klärung, ob es sich tatsächlich um denselben betriebswirtschaftlichen Sachverhalt handelt. Die in Abschnitt 3.4 dargelegte statistische Argumentation – eine Wahrscheinlichkeit von $\approx 10^{-128}$ für zufällige Übereinstimmung aller 64 kontinuierlichen Werte – spricht jedoch klar für die Datenerfassungsfehler-Hypothese.

Konservative Alternative: Eine denkbare, noch vorsichtigere Strategie wäre gewesen, *beide* Instanzen eines Duplikatpaars zu entfernen (Verlust von 802 statt 401 Beobachtungen). Diese Variante hätte jedoch einen Informationsverlust von 1,85 % der Gesamtstichprobe bedeutet – ohne erkennbaren methodischen Mehrwert, da die erste Instanz vermutlich genauso valide ist wie die zweite.

4.1.3 Implementierung und Timing

Die Entfernung erfolgte mittels der Pandas-Operation `drop_duplicates(keep='first')`, die für jedes Duplikatpaar die erste Instanz beibehält und nachfolgende Instanzen entfernt. Die Wahl von `keep='first'` ist arbiträr (gleichwertig wäre `keep='last'` gewesen), jedoch reproduzierbar dokumentiert.

Kritischer methodischer Aspekt – Timing: Die Duplikat-Entfernung erfolgt *vor jeglicher weiterer Datenmanipulation*, insbesondere vor Datenaufteilungen. Dies ist essentiell, um **Data Leakage** zu verhindern: Würde ein Duplikatpaar über verschiedene Datenpartitionen verteilt, könnte dies zu optimistisch verzerrten Performanzmetriken führen (Goodfellow et al., 2016).

4.1.4 Ergebnis und Auswirkungen

Tabelle 4.1 fasst das Ergebnis zusammen.

Die Insolvenzrate verändert sich minimal von 4,82 % auf 4,84 % – eine Verschiebung von lediglich 0,03 Prozentpunkten. Dies deutet darauf hin, dass die Duplikate *nicht* systematisch

Table 4.1: Ergebnis der Duplikat-Entfernung

Metrik	Vorher	Nachher
Beobachtungen	43.405	43.004
Entfernt	–	401
Anteil entfernt	–	0,92 %
Insolvenzrate	4,82 %	4,84 %
Veränderung	–	+0,03 pp

Quelle: Eigene Darstellung basierend auf Script 01a_remove_duplicates.py

häufiger insolvente oder gesunde Unternehmen betrafen, sondern gleichmäßig über beide Klassen verteilt waren. Die Klassenbalance bleibt somit im Wesentlichen erhalten.

4.1.5 Horizontspezifische Verteilung der Duplikate

Eine ergänzende Analyse untersuchte, ob bestimmte Prognosehorizonte überproportional von Duplikaten betroffen waren. Die Duplikatraten variieren zwischen 0,83 % (H3) und 1,17 % (H1) – eine Schwankung von lediglich 0,34 Prozentpunkten. Dies deutet auf ein **horizontübergreifend gleichmäßig verteiltes Datenerfassungsproblem** hin, nicht auf systematische Qualitätsdefizite einzelner Horizonte.

4.1.6 Methodische Reflexion

Die Entfernung von 401 Beobachtungen (0,92 % der Stichprobe) ist ein vertretbarer Preis für die Gewährleistung der Datenintegrität. Zwei alternative Strategien wären denkbar gewesen:

1. **Alle Duplikate behalten:** Führt zu künstlicher Übergewichtung und verzerrten Konfidenzintervallen.
2. **Beide Instanzen entfernen:** Höhere Datenverlustrate ohne erkennbaren methodischen Mehrwert.

Die gewählte Strategie (`keep='first'`) balanciert zwischen Vorsicht und Datenerhalt. Die Limitation – fehlende Verifizierbarkeit mangels Unternehmens-ID – bleibt bestehen, wird jedoch durch die statistische Evidenz (Abschnitt 3.4) hinreichend adressiert.

4.2 Winsorisierung extremer Werte

Finanzielle Kennzahlen sind notorisch anfällig für Extremwerte. Die Gründe reichen von Bilanzmanipulation über Messfehler bis hin zu Sonderereignissen (Restrukturierungen, Fusionen). Abschnitt 3.4 dokumentierte, dass *alle* 64 Kennzahlen Ausreißer aufweisen, mit Anteilen zwischen 0,07 % und 15,5 %. Die Behandlung dieser Extremwerte ist methodische Notwendigkeit, da sie in Regressionsmodellen zu instabilen Parametern führen können (Hastie et al., 2009).

4.2.1 Methodenwahl: Winsorisierung vs. Alternativen

Zur Behandlung von Ausreißern stehen grundsätzlich drei Strategien zur Verfügung:

Option A: Deletion Entfernung aller als Ausreißer klassifizierten Beobachtungen. Diese Methode ist einfach, führt jedoch zu erheblichem Informationsverlust: Bei durchschnittlich 5,4 % Ausreißern pro Feature würde eine zeilenbasierte Deletion potenziell einen Großteil der Stichprobe eliminieren, da viele Beobachtungen in mindestens einer Kennzahl einen Ausreißer aufweisen.

Option B: Log-Transformation Transformation rechtsschiefe Verteilungen mittels Logarithmus. Diese Methode scheitert jedoch bei Finanzkennzahlen systematisch: Viele Ratios können negative Werte annehmen (z. B. negativer Nettogewinn bei Verlusten), was $\log(x)$ für $x \leq 0$ undefiniert macht.

Option C: Winsorisierung Ersetzung von Extremwerten durch weniger extreme Perzentilwerte. Diese Methode dämpft Ausreißer, ohne Beobachtungen zu verlieren oder Vorzeichenprobleme zu verursachen. Sie ist in der empirischen Finanzforschung etabliert und wurde für diese Arbeit gewählt.

4.2.2 Implementierung: 1./99. Perzentil

Die Winsorisierung erfolgte separat für jede der 64 Kennzahlen nach folgendem Schema:

1. Berechnung des 1. Perzentils (P_1) und 99. Perzentils (P_{99}) über alle nicht-fehlenden Werte.
2. Ersetzung aller Werte $x < P_1$ durch P_1 .
3. Ersetzung aller Werte $x > P_{99}$ durch P_{99} .

4. Fehlende Werte bleiben unverändert (werden später imputiert).

Die Wahl der **1./99. Perzentile** (statt z. B. 5./95.) beruht auf zwei Überlegungen: Erstens ist die Ausreißerrate mit durchschnittlich 5,4 % bereits moderat, sodass eine aggressivere Winsorisierung unnötig erscheint. Zweitens soll die ursprüngliche Verteilungsform soweit möglich erhalten bleiben – ein Prinzip, das gegen zu weite Perzentilgrenzen spricht.

4.2.3 Ergebnis und Auswirkungen

Tabelle 4.2 fasst die Auswirkungen zusammen.

Table 4.2: Ergebnis der Winsorisierung

Metrik	Wert
Beobachtungen (unverändert)	43.004
Features winsorisiert	64/64
Werte modifiziert (gesamt)	53.427
Durchschn. Anteil pro Feature	1,94 %
Min. Anteil	0,03 %
Max. Anteil	2,00 %

Quelle: Eigene Darstellung basierend auf Script 01b_outlier_treatment.py

Insgesamt wurden **53.427 Werte** über alle Features hinweg modifiziert – das entspricht durchschnittlich 1,94 % der Werte pro Feature. Dieser Anteil liegt deutlich unter der ursprünglichen Ausreißerrate von 5,4 % ($3 \times \text{IQR}$ -Methode), was erwartbar ist: Die Perzentilmethode ist weniger konservativ als die IQR-basierte Definition und behandelt nur die extremsten 2 % der Verteilung.

4.2.4 Validierung: Erhalt der Stichprobengröße

Ein methodisch kritischer Aspekt ist die Überprüfung, dass durch Winsorisierung *keine* Beobachtungen verloren gehen. Die Verifikation bestätigt: Sowohl die Stichprobengröße (43.004) als auch die Anzahl fehlender Werte (41.037) bleiben unverändert. Dies bestätigt, dass Winsorisierung – im Gegensatz zu Deletion – ein informationserhaltender Prozess ist.

4.2.5 Timing im Preprocessing-Ablauf

Die Winsorisierung erfolgt *nach* Duplikat-Entfernung, aber *vor* Imputation fehlender Werte. Diese Reihenfolge ist methodisch begründet:

- **Nach Duplikaten:** Duplikate müssen zuerst entfernt werden, um nicht künstlich die Perzentilberechnungen zu verzerren.
- **Vor Imputation:** Würden Extremwerte erst *nach* Imputation behandelt, könnten sie die Imputationsstatistiken (Mittelwerte, Mediane) verzerren. Bei MICE-Imputation (siehe Abschnitt 4.3) werden Regressionsmodelle auf beobachteten Daten trainiert. Unbehandelte Extremwerte in den Prädiktoren würden zu instabilen Regressionskoeffizienten führen.

4.2.6 Methodische Reflexion und Limitationen

Die Wahl der Winsorisierung stellt einen Kompromiss dar: (1) Naives Belassen aller Werte führt zu instabilen Modellen; (2) aggressives Löschen führt zu Informationsverlust. Die gewählte Methode balanciert beide Aspekte, bringt jedoch eigene Limitationen mit sich:

1. **Informationsverzerrung:** Winsorisierung verändert die ursprüngliche Verteilung. Extremwerte könnten tatsächlich valide Beobachtungen repräsentieren (z. B. Unternehmen in außergewöhnlichen Situationen).
2. **Grenzwertbestimmung:** Die Wahl der 1./99. Perzentile ist nicht „objektiv richtig“, sondern basiert auf etablierten Konventionen. Alternative Schwellenwerte (z. B. 5./95.) wären ebenfalls vertretbar gewesen.
3. **Feature-Unabhängigkeit:** Die Winsorisierung erfolgt separat je Feature, ohne Berücksichtigung multivariater Ausreißer (Beobachtungen, die in keiner einzelnen Dimension extrem sind, aber in Kombination ungewöhnlich).

Diese Limitationen sind transparent zu kommunizieren, schmälern jedoch nicht die grundsätzliche Notwendigkeit einer Ausreißerbehandlung bei Finanzkennzahlen.

4.3 Imputation fehlender Werte

Die gravierendste Datenqualitätsherausforderung – dokumentiert in Abschnitt 3.4 – besteht in den **41.037 fehlenden Werten** über alle 64 Kennzahlen. Ein Löschen aller betroffenen Zeilen (Listwise Deletion) würde die Stichprobe drastisch reduzieren und ist damit keine Option. Folglich ist Imputation methodische Notwendigkeit. Die folgenden Abschnitte dokumentieren die gewählte Strategie, deren theoretische Fundierung sowie die erzielten Ergebnisse.

4.3.1 Methodenwahl: MICE mit BayesianRidge

4.3.1.1 Grundprinzip: Multiple Imputation by Chained Equations (MICE)

MICE, auch bekannt als Fully Conditional Specification (FCS), ist ein iterativer Ansatz zur Imputation multivariater fehlender Daten (Buuren and Groothuis-Oudshoorn, 2011). Das Grundprinzip:

1. **Initialisierung:** Alle fehlenden Werte werden initial durch einfache Statistiken (Median) ersetzt.
2. **Iteration:** Für jede Variable mit fehlenden Werten:
 - Trainiere ein Regressionsmodell, das diese Variable durch alle anderen Variablen vorhersagt.
 - Imputiere fehlende Werte mittels Vorhersage dieses Modells.
3. **Konvergenz:** Wiederhole Schritt 2, bis sich die imputierten Werte stabilisieren (typisch: 5–20 Iterationen).

Der entscheidende Vorteil von MICE gegenüber univariaten Methoden (Mean/Median Imputation): MICE **berücksichtigt Korrelationen** zwischen Variablen. Beispiel: Wenn eine Profitabilitätskennzahl fehlt, aber Liquiditäts- und Verschuldungskennzahlen bekannt sind, kann MICE deren Beziehung zur Profitabilität nutzen, um einen plausibleren Imputationsswert zu generieren.

4.3.1.2 Wahl des Schätzers: BayesianRidge Regression

Innerhalb von MICE muss spezifiziert werden, welches Modell zur Vorhersage verwendet wird. Für diese Arbeit wurde **BayesianRidge Regression** gewählt, aus folgenden Gründen:

1. **Multikollinearität-Robustheit:** Wie in Abschnitt 3.2 analysiert, weisen die 64 Kennzahlen strukturbedingte Redundanzen auf (inverse Paare, gemeinsame Nenner). Bayesian Ridge Regression integriert Regularisierung, die hohe Korrelationen zwischen Prädiktoren toleriert, ohne numerisch instabil zu werden (Tipping, 2001).
2. **Automatische Unsicherheitsquantifizierung:** Der Bayessche Ansatz liefert nicht nur Punktschätzungen, sondern auch Unsicherheitsmaße, die während der Iteration helfen, Konvergenz zu überwachen.
3. **Vermeidung von Overfitting:** Regularisierung verhindert, dass das Imputationsmodell zu perfekt auf beobachtete Daten fittet – ein Risiko bei hochdimensionalen Daten (64 Prädiktoren).

Alternative Schätzer (z. B. Random Forest, KNN) wurden erwogen, jedoch verworfen: Random Forest ist rechenintensiver und liefert keine linearen Beziehungen (schwer interpretierbar bei Finanzkennzahlen); KNN ignoriert die interne Struktur der Daten.

4.3.2 Direkte Ratio-Imputation (JAV)

Eine zentrale Frage bei **abgeleiteten Variablen** (Ratios) ist, ob man die Ratio selbst imputiert oder die zugrundeliegenden Komponenten (Zähler/Nenner) und die Ratio erst im Anschluss berechnet. Das direkte Imputieren der bereits gebildeten Kennzahl wird in der Literatur als *JAV* – "*Just Another Variable*" bzw. *transform-then-impute* bezeichnet¹. (vgl. auch (Buuren, 2018), § 6.4.1)

Da unser Datensatz ausschließlich bereits berechnete Ratios (A1–A64) enthält und *keine* Rohkomponenten (z. B. Umsatz, Bilanzsumme etc.), ist **JAV die einzig praktikable und methodisch korrekte Vorgehensweise**. Wir imputieren daher die Ratios direkt mittels MICE (Buuren and Groothuis-Oudshoorn, 2011) und nutzen die Korrelationsstruktur zwischen den Ratios, um plausible Werte zu erzeugen. Ansätze, die während der Imputation explizit die funktionale Beziehung zwischen Komponenten und Ratio erzwingen, setzen die Verfügbarkeit der Rohkomponenten voraus und sind hier nicht anwendbar.

4.3.3 Hyperparameter und Implementierungsdetails

Die Imputation wurde mittels `sklearn.impute.IterativeImputer` mit folgenden Einstellungen durchgeführt:

- `estimator=BayesianRidge()`: Schätzer für die Regressionsmodelle
- `max_iter=10`: Maximale Anzahl Iterationen
- `random_state=42`: Seed für Reproduzierbarkeit
- `tol=1e-3`: Konvergenztoleranz

Die Wahl von **10 Iterationen** basiert auf Empirie: Van Buuren (2011) zeigt, dass MICE typischerweise nach 5–10 Iterationen konvergiert (Buuren and Groothuis-Oudshoorn, 2011). Eine Erhöhung auf 20 Iterationen wurde getestet, führte jedoch zu keiner messbaren Verbesserung bei erheblich längerer Laufzeit.

¹White, I. R., Royston, P., Wood, A. M. (2011): Multiple imputation of covariates with non-linear effects and interactions. BMC Medical Research Methodology 11:252. <https://bmcmmedresmethodol.biomedcentral.com/articles/10.1186/1471-2288-12-46>

4.3.4 Qualitätsbewertung der Imputation

Eine kritische Frage lautet: Wie gut sind die imputierten Werte? Absolute Validierung ist unmöglich, da die wahren Werte unbekannt sind. Jedoch lassen sich relative Qualitätsindikatoren berechnen. Für diese Arbeit wurde ein dreistufiges Bewertungssystem entwickelt.

4.3.4.1 Qualitätsmetriken

Für jede Kennzahl wurden folgende Metriken berechnet:

1. **Missing Rate:** Anteil fehlender Werte vor Imputation
2. **Imputed Values:** Anzahl imputierter Werte
3. **Quality Score:** Heuristischer Score (0-100), basierend auf Missing Rate und Verteilungsstabilität

Der Quality Score bewertet niedrige Missing Rates positiv ($< 10\%$ = exzellent, $> 40\%$ = kritisch) und prüft, ob imputierte Werte die Verteilungscharakteristika wahren.

4.3.4.2 Gesamtergebnis

Tabelle 4.3 zeigt das Gesamtergebnis.

Table 4.3: Ergebnis der Missing Value Imputation

Metrik	Wert
Fehlende Werte vorher	41.037
Fehlende Werte nachher	0
Beobachtungen (unverändert)	43.004
Features imputiert	64/64
Durchschn. Quality Score	98,2/100
Bewertung	Exzellent
Features mit Score > 90	63/64
Features mit Score < 50	1/64 (A37)

Quelle: Eigene Darstellung basierend auf Script 01c_missing_value_imputation.py




Figure 4.1: Imputationsqualität: Verteilung der Quality Scores und Diagnostik

Quelle: Eigene Darstellung basierend auf Script 01c_missing_value_imputation.py

Das Ergebnis ist **überzeugend**: Mit einem durchschnittlichen Quality Score von 98,2/100 erreicht die Imputation exzellente Qualität. 63 von 64 Features erreichen Scores über 90, was auf robuste Imputation hindeutet.

4.3.5 Sonderfall A37: Umgang mit hoher Missingness

Kennzahl A37 (*Quick Assets / Long-term Liabilities*) sticht mit **43,7 % fehlenden Werten** und einem Quality Score von **25/100** hervor. Zwei Strategien wurden erwogen:

Option A: Entfernung der Kennzahl Sicher, aber mit Informationsverlust verbunden. A37 ist eine Liquiditätskennzahl und misst die Fähigkeit, langfristige Schulden aus liquiden Mitteln zu bedienen – theoretisch relevant für Insolvenzprognose (Altman, 1968).

Option B: Imputation trotz hoher Missingness Erhalt der Kennzahl, jedoch mit Unsicherheit behaftet. MICE nutzt Beziehungen zu anderen Liquiditäts- und Verschuldungskennzahlen, um plausible Werte zu generieren.

Entscheidung: Option B wurde gewählt. Die theoretische Bedeutung von Liquiditätsindikatoren in der Insolvenzforschung rechtfertigt den Erhalt von A37. Die niedrige Imputationssqualität wird transparent dokumentiert und kann in späteren Sensitivitätsanalysen adressiert werden (Modellierung mit/ohne A37) oder durch datengetriebene Feature Selection (Kapitel 7) evaluiert werden.

Ursache der hohen Missingness Die fehlenden Werte bei A37 sind vermutlich nicht zufällig, sondern strukturbedingt: Unternehmen ohne langfristige Verbindlichkeiten weisen einen undefinierten Nenner auf. Dies ist **informative Missingness** (MAR – Missing At Random), keine Datenqualitätsproblem.

4.3.6 Verifikation der Imputation

Tabelle 4.4 dokumentiert die Verifikation.

Table 4.4: Verifikation der Imputation

Check	Ergebnis	Status
Fehlende Werte	0	✓ Pass
Infinite Werte	0	✓ Pass
Beobachtungen erhalten	43.004	✓ Pass
Features erhalten	64	✓ Pass

Quelle: Eigene Darstellung basierend auf Script 01c_missing_value_imputation.py

Alle Checks bestanden: Der Datensatz ist nach Imputation vollständig (0 % fehlende Werte), enthält keine infiniten Werte und hat die ursprüngliche Dimensionalität beibehalten.

4.3.7 Methodische Reflexion

Die Imputation mittels MICE mit BayesianRidge erzielt exzellente Ergebnisse (Quality Score 98,2/100) und ist methodisch fundiert. Die Limitation bei A37 (Quality 25/100) ist transparent dokumentiert. Alternative Ansätze (z. B. KNN-Imputation, Mean Imputation) würden entweder die Korrelationsstruktur ignorieren oder rechenintensiver sein ohne erkennbaren Mehrwert.

4.4 Zusammenfassung der Data Preparation-Phase

Die Data Preparation-Phase transformierte den problematischen Rohdatensatz (43.405 Beobachtungen, 9,45 % fehlende Werte, 401 Duplikate, systematische Ausreißer) in einen

methodisch fundierten, analysierbaren Datensatz. Tabelle 4.5 fasst die Transformation zusammen.

Table 4.5: Übersicht Phase 01: Data Preparation

Schritt	Maßnahme	Ergebnis
01a: Duplikate	Entfernung exakter Duplikate (<code>keep='first'</code>)	43.004 Beobachtungen (-401)
01b: Ausreißer	Winsorisierung (1./99. Perzentil) über alle 64 Features	53.427 Werte modifiziert (1,94 % pro Feature)
01c: Imputation	MICE mit BayesianRidge (10 Iterationen)	0 % fehlende Werte, Quality Score 98,2/100

Quelle: Eigene Darstellung basierend auf Scripts 01a–01c

4.4.1 Erreichte Datenqualität

Nach Abschluss der Data Preparation-Phase liegt ein Datensatz vor, der folgende Qualitätskriterien erfüllt:

- **Vollständigkeit:** 0 % fehlende Werte (vorher: 41.037 fehlende Werte)
- **Integrität:** Keine Duplikate, keine infiniten Werte
- **Stabilität:** Ausreißer auf 1./99. Perzentile gedämpft
- **Dimensionalität:** Alle 64 Features erhalten (keine Löschung)
- **Stichprobengröße:** 43.004 Beobachtungen (99,08 % des Originals)

4.4.2 Methodische Stärken

Die gewählte Preprocessing-Pipeline weist mehrere methodische Stärken auf:

Evidenzbasierung Alle Methoden (Winsorisierung, MICE mit BayesianRidge, direkte Ratio-Imputation/JAV) sind durch Forschungsliteratur fundiert und in der empirischen Finanzforschung etabliert.

Transparenz Jede Entscheidung ist dokumentiert, Annahmen sind explizit formuliert (z. B. Duplikat-Natur, A37-Erhalt), Limitationen werden nicht verschwiegen.

Reproduzierbarkeit Alle Schritte sind über Python-Skripte vollständig reproduzierbar. Random Seeds gewährleisten identische Ergebnisse bei Wiederholung.

Informationserhalt Im Gegensatz zu aggressiven Deletionsstrategien wurden nur 0,92 % der Beobachtungen entfernt. Alle 64 Features bleiben erhalten.

4.4.3 Dokumentierte Limitationen

Die folgenden Limitationen sind transparent zu kommunizieren:

1. **Duplikat-Verifizierung:** Ohne Unternehmens-ID bleibt die Duplikat-Natur eine plausible Annahme, keine Gewissheit.
2. **Winsorisierung:** Verändert ursprüngliche Verteilung. Extremwerte könnten tatsächlich valide Beobachtungen sein.
3. **A37-Imputation:** Quality Score 25/100 deutet auf unsichere Imputation hin. Sensitivitätsanalyse empfohlen.
4. **Fehlende Rohkomponenten:** Da nur Ratios vorliegen, können Verfahren zur Konsistenzsicherung, die Zähler/Nenner voraussetzen (z. B. Impute-then-Transform), nicht eingesetzt werden.

4.4.4 Bereitschaft für nachfolgende Phasen

Der bereinigte Datensatz (`poland_imputed.parquet`, 43.004 Beobachtungen, 64 Features, 0 % fehlende Werte) bildet die Grundlage für die nachfolgenden Analysephasen:

- **Phase 02:** Explorative Datenanalyse (Kapitel 5) – Verteilungen, Korrelationen, Univariate Tests
- **Phase 03:** Multikollinearitätskontrolle (Kapitel 6) – VIF-Analyse zur Reduktion redundanter Features
- **Phase 04:** Feature Selection (Kapitel 7) – Filter-, Wrapper- und Embedded-Methoden unter EPV-Schutzschranken
- **Phase 05:** Modellierung (Kapitel 8) – Logistische Regression, Random Forest, XGBoost

4.4.5 Kritische Würdigung

Die Data Preparation-Phase demonstriert den **Balanceakt zwischen Datenerhalt und Qualitätssicherung**. Während naive Ansätze entweder Probleme ignorieren (Risiko verzerrter Ergebnisse) oder aggressiv löschen (Risiko massiven Informationsverlusts), wählt die

implementierte Pipeline den methodisch fundierten Mittelweg: Probleme werden behandelt (nicht ignoriert), aber mit minimal-invasiven Methoden (Winsorisierung statt Deletion, Imputation statt Fallausschluss).

Die erreichte Imputationsqualität (98,2/100 durchschnittlich) ist bemerkenswert und bestätigt die Eignung von MICE mit BayesianRidge für hochdimensionale Finanzdaten mit struktureller Multikollinearität. Die transparente Dokumentation der Limitation bei A37 (Quality 25/100) zeigt wissenschaftliche Integrität: Nicht alle Probleme sind perfekt lösbar, aber alle Limitationen müssen kommuniziert werden.

Fazit: Die Data Preparation-Phase hat die identifizierten Qualitätsprobleme methodisch stringent adressiert und einen analysierbaren Datensatz geschaffen, der die Voraussetzungen für rigorose explorative Analysen und Modellierung erfüllt. Die vollständige Reproduzierbarkeit über dokumentierte Python-Skripte gewährleistet die Nachvollziehbarkeit aller Schritte – ein zentrales Gütekriterium wissenschaftlicher Forschung.

5 Explorative Datenanalyse

Die in Kapitel 4 dokumentierte Datenaufbereitung resultierte in einem vollständigen Datensatz mit 43.004 Beobachtungen, 64 Finanzkennzahlen und 0% fehlenden Werten. Bevor jedoch Modelle trainiert werden können, bedarf es einer systematischen explorativen Analyse: Welche Kennzahlen zeigen signifikante Unterschiede zwischen insolventen und gesunden Unternehmen? Wie stark korrelieren die Features untereinander? Entsprechen die beobachteten Zusammenhänge ökonomischen Erwartungen?

Dieses Kapitel dokumentiert die Ergebnisse der **Phase 02: Explorative Datenanalyse**. Abschnitt 5.1 analysiert Verteilungseigenschaften der Kennzahlen und identifiziert systematische Unterschiede zwischen den Klassen. Abschnitt 5.2 präsentiert univariate statistische Tests unter Kontrolle der False Discovery Rate. Abschnitt 5.3 untersucht Korrelationsmuster und validiert deren ökonomische Plausibilität. Die gewonnenen Erkenntnisse bilden die Grundlage für die nachfolgende Multikollinearitätskontrolle (Kapitel 6) und Feature Selection (Kapitel 7).

5.1 Verteilungsanalyse der Finanzkennzahlen

Die Verteilung von Finanzkennzahlen ist selten normalverteilt – extreme Schiefe, Outlier und multimodale Muster sind die Regel, nicht die Ausnahme (Altman, 1968). Eine rigorose Verteilungsanalyse ist daher methodische Notwendigkeit, da sie (1) die Wahl geeigneter statistischer Tests determiniert und (2) potenzielle Datentransformationen aufzeigt.

5.1.1 Stichprobengrößen und Klassenbalance

Die explorative Analyse erfolgte separat für jeden der fünf Prognosehorizonte. Tabelle 5.1 zeigt die Verteilung der Beobachtungen nach Horizont und Insolvenzstatus.

Die Insolvenzrate steigt systematisch von 3,90% in H1 auf 6,97% in H5. Dieses Muster ist erwartbar: In frühen Horizonten (H1, H2) sind finanzielle Schwierigkeiten noch latent, während sie in späten Horizonten (H4, H5) bereits manifest werden. Die deutlich höhere Insolvenzrate in H5 bestätigt, dass die Vorhersage von Insolvenzen, die nur ein Jahr entfernt sind, auf Basis bereits sichtbarer Krisensymptome erfolgt.

Table 5.1: Stichprobengrößen und Insolvenzzraten nach Horizont

Horizont	Gesamt	Insolvent	Gesund	Insolvenzzrate
H1	6.945	271	6.674	3,90 %
H2	10.083	398	9.685	3,95 %
H3	10.416	493	9.923	4,73 %
H4	9.710	513	9.197	5,28 %
H5	5.850	408	5.442	6,97 %
Gesamt	43.004	2.083	40.921	4,84 %

Quelle: Eigene Darstellung basierend auf Script 02a_distribution_analysis.py

5.1.2 Schiefe und Verteilungseigenschaften

Finanzielle Kennzahlen weisen typischerweise rechtsschiefe Verteilungen auf. Die Analyse bestätigt dieses Muster: Im Horizont H1 zeigen **35 von 64 Kennzahlen** (54,7%) eine extreme Schiefe ($|\text{Skewness}| > 2$). Die durchschnittliche absolute Schiefe über alle Features beträgt 3,14, mit einem Maximum von 9,23.

Diese ausgeprägte Nicht-Normalität hat methodische Konsequenzen: Parametrische Tests (t-Test), die Normalverteilung voraussetzen, sind für diese Daten ungeeignet. Die Wahl nicht-parametrischer Verfahren (siehe Abschnitt 5.2) ist damit methodisch zwingend.




Figure 5.1: Schiefe-Übersicht (H1): Anteile extremer Schiefe je Kennzahl

Quelle: Eigene Darstellung basierend auf Script 02a_distribution_analysis.py

5.2 Univariate Signifikanztests mit FDR-Kontrolle

Für jede der 64 Kennzahlen wurde ein univariater Test durchgeführt, um zu prüfen, ob die Verteilung zwischen insolventen und gesunden Unternehmen signifikant unterschiedlich ist. Diese Tests bilden die Grundlage für die Identifikation prädiktiv relevanter Features.

5.2.1 Methodologie

Die Testprozedur folgt einem mehrstufigen Ansatz:

Schritt 1: Normalitätstest Für jede Kennzahl wurde mittels **D’Agostino-Pearson K²-Test** geprüft, ob die Verteilung in beiden Gruppen (insolvent/gesund) als normalverteilt angenommen werden kann. Dieser Test ist für große Stichproben ($n > 5.000$) geeigneter als der Shapiro-Wilk-Test (D’Agostino and Pearson, 1973). Zusätzlich wurden Schiefe und Kurtosis berechnet; Features mit $|\text{Skewness}| > 2$ oder $|\text{Kurtosis}| > 5$ wurden automatisch als nicht-normal klassifiziert.

Schritt 2: Testvarianten Basierend auf dem Normalitätsergebnis wurde der geeignete Test gewählt:

- **Bei Normalverteilung beider Gruppen:** Student’s t-Test (bei Varianzhomogenität) oder Welch’s t-Test (bei Varianzheterogenität, geprüft mittels Levene-Test (Levene, 1960)).
- **Bei Nicht-Normalverteilung:** Mann-Whitney U-Test (nicht-parametrisch, verteilungsfrei; (Mann and Whitney, 1947)).

Schritt 3: Effektstärken Neben p-Werten wurden standardisierte Effektstärken berechnet:

- **Cohen’s d** für parametrische Tests (Interpretation nach (Cohen, 1988): $|d| < 0,5$ = klein, $0,5-0,8$ = mittel, $> 0,8$ = groß)
- **Rank-biserial correlation** für nicht-parametrische Tests (analog zu Cohen’s d interpretierbar)

Schritt 4: FDR-Korrektur Um die Inflation des Fehlers 1. Art bei multiplen Tests zu kontrollieren, wurde die **Benjamini-Hochberg False Discovery Rate (FDR)** Prozedur angewendet (Benjamini and Hochberg, 1995). Dies ist weniger konservativ als die Bonferroni-Korrektur und für explorative Analysen geeigneter. Die FDR-Korrektur wurde *je Horizont separat* angewendet (64 Tests pro Horizont), entsprechend der horizont-spezifischen Modellierung in dieser Arbeit.

Table 5.2: Univariate Testergebnisse nach Horizont

Horizont	Features	Sig. ($p < 0,05$)	Sig. (FDR $q < 0,05$)	Verlust	Parametrisch
H1	64	53 (82,8 %)	53 (82,8 %)	0	0
H2	64	52 (81,2 %)	50 (78,1 %)	2	0
H3	64	54 (84,4 %)	54 (84,4 %)	0	1
H4	64	58 (90,6 %)	58 (90,6 %)	0	0
H5	64	57 (89,1 %)	57 (89,1 %)	0	0
Gesamt	320	274 (85,6 %)	272 (85,0 %)	2	1

Quelle: Eigene Darstellung basierend auf Script 02b_univariate_tests.py

5.2.2 Ergebnisse über alle Horizonte

Tabelle 5.2 fasst die Testergebnisse zusammen.

Drei zentrale Erkenntnisse lassen sich ableiten:

Robuste Signifikanz nach FDR-Kontrolle Von 320 Tests (64 Features $\times$ 5 Horizonte) bleiben nach Benjamini-Hochberg-Korrektur **272 signifikant** (85,0 %). Der Verlust von lediglich 2 Features (beide in H2) zeigt, dass die Unterschiede zwischen den Gruppen robust sind und nicht auf Zufall beruhen.

Nahezu ausschließlich nicht-parametrische Tests In nur **1 von 320 Tests** (0,3 %) konnte Normalverteilung angenommen werden. Dies bestätigt die in Abschnitt 5.1.2 dokumentierte extreme Schiefe der Finanzkennzahlen und rechtfertigt die Wahl nicht-parametrischer Verfahren.

Steigende Diskriminierungsfähigkeit mit abnehmendem Horizont Die Anzahl signifikanter Features steigt von 53 (H1) auf 58 (H4), was erwartbar ist: Je näher die Insolvenz, desto deutlicher manifestieren sich die finanziellen Probleme in den Kennzahlen.

5.2.3 Beispielhafte Top-Features (Horizont H1)

Die fünf Features mit den stärksten Effekten in H1 sind: A24 (Effekt: 0,46), A13 (0,43), A26 (0,42), A16 (0,41) und A23 (0,40). Alle zeigen mittlere Effektstärken und wurden mittels Mann-Whitney U-Test als hochsignifikant identifiziert (q -Werte $< 10^{-27}$). Diese Features gehören überwiegend zur Kategorie Profitabilität und zeigen die erwartete negative Korrelation mit Insolvenz.

5.3 Korrelationsanalyse und ökonomische Validierung

Multikollinearität – hohe Korrelationen zwischen Prädiktoren – ist bei Finanzkennzahlen unvermeidlich (Altman, 1968). Viele Ratios teilen gemeinsame Nenner (z. B. Bilanzsumme) oder sind mathematisch verwandt (z. B. inverse Paare). Diese Struktureigenschaft erfordert eine systematische Korrelationsanalyse, um (1) das Ausmaß der Multikollinearität zu quantifizieren und (2) ökonomisch plausible von implausiblen Mustern zu unterscheiden.

5.3.1 Ausmaß der Multikollinearität

Für jeden Horizont wurde die Pearson-Korrelationsmatrix (64×64) berechnet. Als „hohe Korrelation“ wurden Paare mit $|r| > 0,8$ definiert – dieser Schwellenwert entspricht einem gängigen Interpretationsrahmen für starke Korrelationen (vgl. (Schober et al., 2018)) und ist konsistent mit der Literatur zu Multikollinearität (O’Brien, 2007). Tabelle 5.3 zeigt die Ergebnisse.

Table 5.3: Multikollinearität nach Horizont

Horizont	Hohe Korrelationen ($ r > 0,8$)	Max. mögliche	Anteil (%)
H1	73	2.016	3,6 %
H2	70	2.016	3,5 %
H3	65	2.016	3,2 %
H4	68	2.016	3,4 %
H5	62	2.016	3,1 %
Durchschnitt	68	2.016	3,4 %

Quelle: Eigene Darstellung basierend auf Script 02c_correlation_economic.py. Max. mögliche Paare:
 $\binom{64}{2} = 2.016$




Figure 5.2: Korrelationsheatmap (H1): Pearson-Korrelationen der 64 Kennzahlen

Quelle: Eigene Darstellung basierend auf Script 02c_correlation_economic.py

Im Durchschnitt zeigen **68 Feature-Paare** (3,4%) hohe Korrelationen. Dieses Muster ist über alle Horizonte stabil (Schwankung: 62–73). Die moderate Quote zeigt: Während Multikollinearität vorhanden ist, betrifft sie nur einen kleinen Teil der Feature-Paare. Dies wird auch in der Heatmap (Abbildung 5.2) deutlich sichtbar: Außerhalb der Diagonale (Selbstkorrelation = 1, rot) treten nur vereinzelt intensive Färbungen auf, was die begrenzte Anzahl hochkorrelierter Paare visuell bestätigt. Dennoch ist eine systematische Behandlung mittels VIF-Analyse notwendig (siehe Kapitel 6: Multikollinearitätskontrolle). Dieses Muster ist über alle Horizonte stabil (Schwankung: 62–73). Die moderate Quote zeigt: Während Multikollinearität vorhanden ist, betrifft sie nur einen kleinen Teil der Feature-Paare. Dennoch ist eine systematische Behandlung mittels VIF-Analyse notwendig (siehe Kapitel 6: Multikollinearitätskontrolle).

5.3.2 Ökonomische Plausibilitätsvalidierung

Nicht alle Korrelationen mit der Zielvariable (Insolvenz) sind ökonomisch sinnvoll. Ein Feature könnte statistisch signifikant mit Insolvenz korrelieren, aber in die „falsche“ Richtung weisen. Beispiel: Eine hohe Verschuldungskennzahl sollte positiv mit Insolvenz korrelieren – zeigt sie eine negative Korrelation, deutet dies auf Datenprobleme oder nicht-lineare Zusammenhänge hin.

Für jedes der 64 Features wurde basierend auf der Kategorie (Profitabilität, Liquidität, Verschuldung, etc.) eine ökonomisch erwartete Richtung definiert. Tabelle 5.4 zeigt die Validierungsergebnisse für H1.

Table 5.4: Ökonomische Plausibilität der Feature-Insolvenz-Korrelationen (H1)

Kategorie	Anzahl Features	Plausibel	Implausibel
Profitabilität	20	18	2
Liquidität	10	8	2
Verschuldung	17	10	7
Aktivität	15	5	10
Größe	1	1	0
Sonstige	1	0	1
Gesamt	64	42 (65,6 %)	22 (34,4 %)

Quelle: Eigene Darstellung basierend auf Script 02c_correlation_economic.py

42 von 64 Features (65,6 %) zeigen ökonomisch plausible Korrelationen mit Insolvenz. Die Implausibilitätsrate von 34,4 % ist methodisch bemerkenswert und konzentriert sich auf zwei Kategorien:

Verschuldungskennzahlen 7 von 17 Features (41 %) zeigen implausible Muster. Dies könnte auf nicht-lineare Zusammenhänge hindeuten: Extrem hohe Verschuldung führt zur Insolvenz, aber auch extrem niedrige Verschuldung (kein Zugang zu Kreditmärkten) kann problematisch sein.

Aktivitätskennzahlen 10 von 15 Features (67 %) sind implausibel. Aktivitätskennzahlen (z. B. Umschlagshäufigkeiten) sind komplex interpretierbar und möglicherweise branchenabhängig.

Diese Erkenntnisse haben methodische Konsequenzen für die Feature Selection: Implausible Features sollten kritisch geprüft werden – entweder durch Entfernung oder durch nicht-lineare Modellierung.

5.4 Zusammenfassung der explorativen Erkenntnisse

Die explorative Datenanalyse liefert vier zentrale Erkenntnisse, die die nachfolgende Modellierung determinieren:

- 1. Extreme Nicht-Normalität** 35 von 64 Features (55 %) zeigen extreme Schiefe. Nur 1 von 320 Tests erfüllte Normalitätsannahmen. **Implikation:** Nicht-parametrische Methoden oder Datentransformationen sind notwendig.
- 2. Robuste Diskriminierungsfähigkeit** 272 von 320 Tests (85 %) bleiben nach FDR-Kontrolle signifikant. Der Verlust von nur 2 Features zeigt robuste Unterschiede zwischen Klassen. **Implikation:** Die Datenbasis ist für prädiktive Modellierung geeignet.
- 3. Begrenzte Multikollinearität (Korrelationsanalyse)** Durchschnittlich 68 Feature-Paare (3,4 %) zeigen hohe Korrelationen ($|r| > 0,8$). **Implikation:** Korrelationsbasierte Multikollinearität betrifft nur einen kleinen Teil der Features, dennoch ist eine VIF-basierte Analyse zur Identifikation indirekter Kollinearitäten notwendig.
- 4. Substanzielle ökonomische Implausibilität** 22 von 64 Features (34 %) zeigen Korrelationen entgegen ökonomischer Erwartungen. **Implikation:** Mechanistische Interpretation ist limitiert; datendrivene Ansätze (z. B. Feature Importance aus Random Forests) könnten sinnvoller sein als rein theoriegeleitete Selektion.

Die gewonnenen Erkenntnisse bilden die Grundlage für Kapitel 6 (Multikollinearitätskontrolle), in dem mittels Variance Inflation Factor (VIF) Analyse systematisch multikollineare Features identifiziert und entfernt werden, um ein reduziertes, modellierbares Feature-Set zu erhalten.

6 Multikollinearitätskontrolle

Die in Kapitel 5 dokumentierte Korrelationsanalyse identifizierte durchschnittlich 68 Feature-Paare (3,4%) mit hohen paarweisen Korrelationen ($|r| > 0,8$). Allerdings erfasst die Korrelationsanalyse nur *direkte* lineare Abhängigkeiten zwischen zwei Variablen. Multikollinearität kann jedoch auch *indirekt* auftreten: Ein Feature kann mit mehreren anderen Features schwach korreliert sein, während die Gesamtkorrelation dieser Gruppe hoch ist. Solche Muster sind nur durch multivariate Verfahren detektierbar (O’Brien, 2007).

Dieses Kapitel dokumentiert die Ergebnisse der **Phase 03: VIF-basierte Multikollinearitätskontrolle**. Abschnitt 6.1 erläutert die Methodik des Variance Inflation Factor (VIF) und begründet den gewählten Schwellenwert. Abschnitt 6.2 präsentiert die Ergebnisse des iterativen VIF-Pruning-Algorithmus über alle fünf Horizonte. Abschnitt 6.3 analysiert die entfernten Features und validiert die Ergebnisse. Die finalen Feature-Sets bilden die Eingangsbasis für die Feature Selection in Kapitel 7.

6.1 Methodologie: Variance Inflation Factor

6.1.1 Definition und Interpretation

Der Variance Inflation Factor (VIF) quantifiziert, um welchen Faktor die Varianz des geschätzten Regressionskoeffizienten $\hat{\beta}_j$ durch Multikollinearität aufgebläht wird (Penn State Eberly College of Science, 2024). Für das j -te Feature wird der VIF berechnet als:

$$\text{VIF}_j = \frac{1}{1 - R_j^2} \quad (6.1)$$

wobei R_j^2 das Bestimmtheitsmaß einer Hilfsregression ist, in der das j -te Feature auf alle verbleibenden Features regressiert wird. Der VIF quantifiziert damit nicht nur die paarweise Korrelation, sondern die *Gesamtkorrelation* des j -ten Features mit allen anderen Prädiktoren.

Interpretation nach Penn State STAT 462 (Penn State Eberly College of Science, 2024):

- $\text{VIF}_j = 1$: Keine Korrelation mit anderen Prädiktoren
- $\text{VIF}_j > 4$: Multikollinearität vorhanden, nähere Untersuchung empfohlen

- $VIF_j > 10$: Ernsthafte Multikollinearität, Korrektur erforderlich

6.1.2 Schwellenwert-Begründung

In dieser Analyse wurde der konservative Schwellenwert **VIF > 10** gewählt. Diese Entscheidung basiert auf drei Argumenten:

1. Ökonometrischer Standard Der Schwellenwert $VIF > 10$ ist in der ökonometrischen Literatur etabliert (O'Brien, 2007; Penn State Eberly College of Science, 2024). O'Brien (2007) zeigt, dass VIF-Werte über 10 mit substanziellen Problemen in der Koeffizientenschätzung einhergehen (aufgeblähte Standardfehler, instabile Schätzer).

2. Konservatismus Ein höherer Schwellenwert (z. B. $VIF > 10$ statt > 5) minimiert das Risiko, prädiktiv wertvolle Features irrtümlich zu entfernen. Da in nachfolgenden Phasen weitere Feature-Selection-Mechanismen (z. B. Lasso-Regularisierung, Random Forest Feature Importance) zum Einsatz kommen, ist ein konservativerer VIF-Schwellenwert methodisch vertretbar.

3. Konsistenz mit Korrelationsanalyse Im bivariaten Fall gilt bei $r = 0,8$: $VIF = 1/(1 - r^2) \approx 2,78$. Der gewählte VIF-Schwellenwert 10 ist damit deutlich konservativer und fängt primär *multiple* Kollinearitäten auf, die die Korrelationsanalyse nicht erfasst.

6.1.3 Iterativer Pruning-Algorithmus

Multikollinearität ist ein *relatives* Phänomen: Das Entfernen eines Features verändert die VIF-Werte aller verbleibenden Features (O'Brien, 2007). Ein iterativer Ansatz ist daher notwendig:

1. **Berechnung:** VIF für alle Features im aktuellen Set
2. **Test:** Falls $\max(VIF) \leq 10$: Konvergenz, Stopp
3. **Entfernung:** Sonst: Entferne Feature mit höchstem VIF
4. **Wiederholung:** Gehe zu Schritt 1

Der Algorithmus terminiert durch Konstruktion: In jeder Iteration wird ein Feature entfernt; Abbruch erfolgt, wenn der Schwellenwert erreicht ist, die maximale Iterationszahl (100) überschritten wäre oder nur noch ≤ 2 Features verbleiben. Die maximale VIF sinkt typischerweise über die Iterationen, kann aber nicht in jedem Schritt streng monoton sein.

6.2 Ergebnisse der VIF-Analyse

6.2.1 Überblick über alle Horizonte

Tabelle 6.1 fasst die Ergebnisse des iterativen VIF-Pruning über alle Horizonte zusammen.

Table 6.1: Zusammenfassung der VIF-basierten Multikollinearitätskontrolle

Horizont	Initial	Final	Entfernt	Iterationen	Max VIF (final)
H1	64	40	24	25	8,91
H2	64	41	23	24	9,87
H3	64	42	22	23	9,99
H4	64	43	21	22	9,87
H5	64	41	23	24	8,53
Durchschnitt	64	41,4	22,6	23,6	9,43

Quelle: Eigene Darstellung basierend auf Script 03a_vif_analysis.py




Figure 6.1: Entfernte Features pro Horizont (Schwellenwert: VIF > 10)

Quelle: Eigene Darstellung basierend auf 03a_ALL_vif.xlsx

Vier zentrale Befunde lassen sich ableiten:

Substanzielle Dimensionsreduktion Im Durchschnitt wurden **22,6 Features** (35,3 % der initialen 64) entfernt. Die finale Feature-Anzahl variiert zwischen 40 (H1) und 43 (H4), was auf horizont-spezifische Kollinearitätsmuster hindeutet.

Zuverlässige Konvergenz Alle fünf Horizonte konvergierten innerhalb von 22–25 Iterationen. Der maximale finale VIF liegt bei 9,99 (H3), knapp unter dem Schwellenwert von 10. Dies bestätigt, dass der Algorithmus erfolgreich alle kritischen Multikollinearitäten eliminiert hat.

Konsistenz der Ergebnisse Die Anzahl entfernter Features ist über die Horizonte stabil (Schwankung: 21–24). Dies ist erwartbar, da die Feature-Sets je Horizont identisch starten (64 Features) und strukturelle Multikollinearitäten (inverse Paare, gemeinsame Nenner) horizont-unabhängig sind.

Moderate Variabilität Die höhere Anzahl entfernter Features in H1 (24) gegenüber H4 (21) könnte auf stichprobengrößen-bedingte Unterschiede in der Korrelationsstruktur zurückzuführen sein: H1 hat nur 6.945 Beobachtungen (kleinste Stichprobe), H4 hingegen 9.710. Größere Stichproben führen zu stabileren Korrelationsschätzungen und möglicherweise weniger „falsch hohen“ VIFs.

6.2.2 Detaillierte Analyse: Horizont H1

Tabelle 6.2 zeigt die ersten 10 entfernten Features in H1 (vollständige Liste: siehe Appendix).

Table 6.2: In H1 entfernte Features (Top 10 nach VIF bei Entfernung)

Kennzahl (Code)	VIF bei Entfernung	Iteration	Kategorie
Gross Profit + Interest / Assets (A14)	1.808.694.888	1	Profitabilität
EBIT / Assets (A7)	1.757.227	2	Profitabilität
GP + Depr. / Liabilities (A16)	226,61	3	Verschuldung
Payables Days (A32)	170,95	4	Aktivität
Equity / Liabilities (A8)	137,57	5	Verschuldung
Gross Margin (A19)	128,06	6	Profitabilität
Gross Profit / Assets (A18)	79,11	7	Profitabilität
Constant Capital / Fixed Assets (A54)	71,94	8	Verschuldung
Equity / Assets (A10)	56,72	9	Verschuldung
Operating Profit / Assets (A22)	48,85	10	Profitabilität

Quelle: Eigene Darstellung basierend auf 03a_H1_vif.xlsx / Skriptausgabe (Iteration 1–10)

Extreme Anfangs-VIFs Feature A14 (Gross Profit + Interest / Assets) wurde in der ersten Iteration mit einem VIF von **1,8 Milliarden** entfernt – ein Indikator für nahezu perfekte Kollinearität. Die Inspektion der Korrelationsanalyse (H1, Phase 02c) zeigt: A7 (EBIT / Assets) $\leftrightarrow$ A14 (Gross Profit + Interest / Assets): $r = 1,000$, ebenso A14 (Gross Profit + Interest / Assets) $\leftrightarrow$ A18 (Gross Profit / Assets) und A7 (EBIT / Assets) $\leftrightarrow$ A18 (Gross Profit / Assets). Diese Features sind mathematische Transformationen voneinander (z. B. inverse Ratios).

Schnelle VIF-Reduktion Nach Entfernung der ersten drei Features sinkt der maximale VIF von 1,8 Milliarden (Iteration 1) auf 226 (Iteration 3), dann auf 137 (Iteration 5). Die initiale Multikollinearität ist damit primär durch eine kleine Gruppe hochkollinearer Features getrieben.

Kategorie-Verteilung Von den ersten 10 entfernten Features gehören 5 zu „Profitabilität“, 4 zu „Verschuldung“ und 1 zu „Aktivität“ (keine „Liquidität“). Dies spiegelt die ökonomische Realität wider: Profitabilitätskennzahlen (z. B. ROE, ROA, Gewinnmargen) teilen häufig gemeinsame Nenner (Eigenkapital, Bilanzsumme) und sind daher anfällig für Multikollinearität.

6.2.3 Horizont-übergreifende Muster

Eine Frage lautet: *Welche Features werden konsistent über alle Horizonte entfernt?*

Eine konsolidierte Sicht der Datei 03a_ALL_vif.xlsx (Sheet „All_Removed“) zeigt, dass mehrere Features in vielen Horizonten entfernt werden (z. B. A14 (Gross Profit + Interest / Assets), A7 (EBIT / Assets), A8 (Equity / Liabilities), A18 (Gross Profit / Assets), A19 (Gross Margin), A22 (Operating Profit / Assets), A32 (Payables Days), A54 (Constant Capital / Fixed Assets), A63 (Payables Turnover)). Die vollständige Liste und Häufigkeiten sind im konsolidierten Output dokumentiert und bilden eine belastbare Grundlage für eine optionale „gemeinsame“ Feature-Definition über Horizonte.

18 Features wurden in mindestens 4 von 5 Horizonten entfernt, davon **15 in allen 5 Horizonten**. Dies zeigt: Die VIF-basierte Multikollinearität ist primär strukturell (mathematische Abhängigkeiten zwischen Ratios) und nicht stichprobenbedingt. Diese 15 Features sind *systematisch redundant* und können für künftige Modellierungen ausgeschlossen werden.

6.3 Validierung und methodische Reflexion

6.3.1 Konsistenz mit Korrelationsanalyse

Ein kritischer Test der VIF-Ergebnisse ist deren Konsistenz mit der Korrelationsanalyse (Abschnitt 5.3): Features mit hohen paarweisen Korrelationen sollten auch hohe VIFs zeigen. Die Inspektion der entfernten Features bestätigt dies:

- **Perfekte Korrelationen:** Features A7 (EBIT / Assets), A14 (Gross Profit + Interest / Assets), A18 (Gross Profit / Assets) zeigen $r = 1,000$ (Phase 02c, H1) und wurden in Iteration 1–3 entfernt.

- **Hohe Korrelationen:** Features A32 (Payables Days) $\leftrightarrow$ A52 (Payables Days (COGS)): $r = 0,996$; A16 (GP + Depr. / Liabilities) $\leftrightarrow$ A26 (NP + Depr. / Liabilities): $r = 0,993$ wurden früh entfernt.

Umgekehrt wurden Features *ohne* hohe paarweise Korrelationen entfernt, wenn sie multivariate Kollinearitäten aufwiesen. Beispiel: Feature A49 (EBITDA Margin; Iteration 13) zeigt keine Korrelation $> 0,8$ mit einem einzelnen Feature, aber viele Korrelationen $> 0,5$ mit mehreren Features, was zu einem VIF von 38,42 führt.

Dies bestätigt: VIF erfasst komplexere Abhängigkeitsstrukturen als pairwise Korrelationen.

6.3.2 Finales Feature-Set: Ökonomische Interpretierbarkeit

Die finalen Feature-Sets (40–43 Features je Horizont) umfassen alle Kategorien:

- **Profitabilität:** 12–14 Features (z. B. Gewinnmargen, ROE-Varianten)
- **Liquidität:** 6–8 Features (z. B. Current Ratio, Quick Ratio)
- **Verschuldung:** 8–10 Features (z. B. Debt-to-Equity Ratio)
- **Aktivität:** 6–8 Features (z. B. Umschlagshäufigkeiten)
- **Größe & Sonstige:** 2–3 Features

Diese Verteilung gewährleistet eine *balanced* Repräsentation aller finanzwirtschaftlichen Dimensionen. Insbesondere wurden nicht alle Profitabilitätskennzahlen entfernt (trotz hoher Kollinearität), sondern nur die redundanten Varianten. Dies sichert die ökonomische Interpretierbarkeit der späteren Modelle.

6.3.3 Methodische Limitationen

Trotz der robusten Ergebnisse existieren methodische Einschränkungen:

VIF-Tie-Breaking Bei gleichen VIF-Werten erfolgt implizit ein Tie-Break nach Spaltenreihenfolge; alternativ wären regelbasierte Kriterien (z. B. ökonomische Relevanz oder Korrelation mit der Zielvariable) sinnvoll. Exakte Ties sind selten, können aber auftreten.

Linearitätsannahme VIF basiert auf linearen Regressionen und erfasst daher nur lineare Abhängigkeiten. Nicht-lineare Kollinearitäten (z. B. quadratische Beziehungen) werden nicht detektiert. Für Finanzdaten mit potentiell nicht-linearen Mustern ist dies eine relevante Einschränkung.

Horizont-spezifische Modellierung Die VIF-Analyse erfolgte separat je Horizont. Eine alternative Strategie wäre: Ein *gemeinsames* Feature-Set für alle Horizonte definieren (Intersection der finalen Sets). Dies würde die Vergleichbarkeit zwischen Horizonten erhöhen, aber möglicherweise prädiktive Performance kosten, da horizont-spezifische Features verloren gehen.

6.4 Zusammenfassung und Konsequenzen

Die VIF-basierte Multikollinearitätskontrolle reduzierte die Feature-Anzahl von 64 auf durchschnittlich 41,4 (Reduktion: 35,3 %). Alle Horizonte konvergierten erfolgreich mit maximalen finalen VIF-Werten $\leq 9,99$. Die Ergebnisse sind konsistent mit der Korrelationsanalyse, gehen jedoch darüber hinaus, indem sie multivariate Kollinearitäten identifizieren.

Drei zentrale Implikationen für die nachfolgende Modellierung:

1. Reduzierte Modellkomplexität Mit 40–43 Features statt 64 wird die Parameterzahl bei Logit-Modellen um 35 % reduziert. Dies senkt das Risiko von Overfitting und verbessert die Interpretierbarkeit.

2. Stabilere Koeffizientenschätzung Durch die Elimination von Features mit $VIF > 10$ werden aufgeblähte Standardfehler vermieden. Die geschätzten Koeffizienten sind präziser und robuster gegenüber Stichprobenvariationen.

3. Erhaltung ökonomischer Diversität Trotz Reduktion sind alle finanzwirtschaftlichen Dimensionen (Profitabilität, Liquidität, Verschuldung, Aktivität) im finalen Set vertreten. Die ökonomische Interpretierbarkeit bleibt erhalten.

Die finalen Feature-Sets wurden persistiert (data/processed/feature_sets/H1_features.json bis H5_features.json) und bilden die Eingangsbasis für die Feature Selection in Kapitel 7. Nach der Feature Selection erfolgt die finale Modellierung in Kapitel 8.

7 Feature Selection

7.1 Ziel und Einordnung

In dieser Phase wird die Eingangsmenge an Merkmalen für die Insolvenzprognose *ökonomisch* und *validierungsstabil* reduziert. Die Auswahl dient drei Zielen: (i) Reduktion von Varianz und Komplexität, (ii) Vermeidung von Scheinkorrelationen und Datenleckage, (iii) Erhöhung der Interpretierbarkeit entlang betriebswirtschaftlicher Kategorien (Profitabilität, Liquidität, Leverage u. a.). Die Selektion erfolgt horizontspezifisch (H1–H5), da sich Informationshorizonte in ihren Signalträgern unterscheiden können. Die Entscheidung gegen rein *black-box* getriebene Verfahren (z. B. tiefe neuronale Netze) erfolgt zugunsten prüffähiger, parsimonier Modelle mit expliziter Variablenlogik und belastbaren Stichprobenanforderungen (EPV) (Rudin, 2019; Wooldridge, 2010).

7.2 Methodischer Rahmen und Gütekriterien

Als prädiktive Gütekriterien werden ROC-AUC und PR-AUC verwendet; die PR-AUC ist bei Klassenungleichgewicht aussagekräftiger (Saito and Rehmsmeier, 2015). Ergänzend wird die *Stabilität der Auswahl* nach Nogueira berichtet (Nogueira et al., 2018), welche die Übereinstimmung der in den Validierungsfalten ausgewählten Merkmale quantifiziert. Ökonometrische Schutzschranken (“Guardrails”) steuern die Komplexität: Es gilt mindestens *Events-per-Variable* $EPV \geq 10$ als konservative Daumenregel (Peduzzi et al., 1996; Steyerberg, 2019); zusätzlich wird gefordert, dass eine reduzierte Merkmalsmenge mindestens einen festgelegten Anteil der Baseline-Leistung beibehält.

7.3 Vorgehensmodell

Die Auswahl erfolgt methodenplural in drei Gruppen, um komplementäre Stärken auszunutzen und bekannte Verzerrungen einzelner Selektoren abzufedern (Guyon and Elisseeff, 2003; Meinshausen and Bühlmann, 2010).

7.3.1 Filtermethoden

Filtermethoden bewerten jedes Merkmal unabhängig vom Modell. Eingesetzt werden Spearman-Rangkorrelation (monotone Zusammenhänge), Mutual Information (nichtlineare

Informationsgehalte) und ANOVA-F als parametrische Referenz. Da Finanzkennzahlen häufig nicht-normal und schief verteilt sind (McLeay and Omar, 2000), werden parametrische Annahmen (ANOVA-F) durch nichtparametrische bzw. informations-theoretische Größen (Spearman, MI) flankiert. Filter liefern robuste Grobvorschläge, sind jedoch blind für multivariate Substitutionseffekte.

7.3.2 Wrappermethoden

Wrapper (hier RFECV) nutzen ein Modell im Loop und entfernen Merkmale iterativ unter Kreuzvalidierung. Vorteile liegen in der Berücksichtigung von Interaktionen; Nachteile in Rechenaufwand und potenzieller Instabilität bei kleinen Effekten. Der Einsatz dient als Gegenpol zu rein univariaten Filtern (Guyon and Elisseeff, 2003).

7.3.3 Eingebettete Methoden

Eingebettete lineare Verfahren koppeln Auswahl und Schätzung: Lasso (L1), Elastic Net (L1/L2; *saga*) und Ridge (L2). Lasso fördert Sparsity, Elastic Net stabilisiert bei korrelierten Prädiktoren (Gruppenstruktur), Ridge liefert kontinuierliche Rangfolgen über Koeffizientenbeträge (Hastie et al., 2009). Eine *Pluralität* eingebetteter Verfahren erhöht die Chance, stabile *Kerne* relevanter Merkmale zu identifizieren, wie auch Konzepte der Stability Selection nahelegen (Meinshausen and Bühlmann, 2010). Als nichtlineare Referenz dient Random-Forest-Importance.

7.4 Vom einfachen zum verschachtelten Ansatz

Ein lediglich äußerer CV-Ansatz kann Auswahl-Bias erzeugen, wenn dieselben Daten die Merkmalsauswahl und die Leistungsbewertung speisen (Leckage). Um dies zu vermeiden, wird eine *verschachtelte Kreuzvalidierung* verwendet: Pro äußerem Fold erfolgt die Merkmalsauswahl ausschließlich im Trainingssplit; die Bewertung wird auf dem zugehörigen Validierungssplit vorgenommen. Damit wird Auswahl-Bias reduziert und die Leistungsschätzung entkoppelt (Cawley and Talbot, 2010; Varma and Simon, 2006); zugleich wird Stabilität methodenübergreifend messbar.

7.5 Stabilität der Auswahl

Die Stabilität wird als korrigierte durchschnittliche Ähnlichkeit der foldweisen Auswahlen (nach Nogueira) definiert (Nogueira et al., 2018). Universelle Grenzwerte existieren nicht;

empfohlen wird die *relative* Interpretation im Methodenvergleich und über Horizonte hinweg. Werte näher an 1 deuten auf konsistentere Muster hin, Werte nahe 0 auf starke Variation.

7.6 Konsensbildung unter Guardrails

Aus den methodenspezifischen Auswahlen werden Konsensmengen konstruiert (Schnittmenge bzw. Mehrheitsregel). Anschließend werden Schutzschranken angewendet: (i) **EPV-Deckelung**: bei E Ereignissen sind höchstens $\lfloor E/10 \rfloor$ Variablen zulässig; (ii) **Leistungs-Retention**: die reduzierte Menge muss mindestens einen festen Anteil der Baseline-ROC-AUC erreichen. Diese Schritte verhindern Überanpassung und sichern Interpretierbarkeit.

7.7 Ergebnisse für H1 (verschachtelte Analyse)

Für H1 liegen verschachtelte Ergebnisse vor (5 Außenfalten; VIF-bereinigter Merkmalsraum gemäß Phase 03):

- **Stabilität (Nogueira)**: Ridge 0,454, Lasso 0,327, Elastic Net 0,050. Im *relativen* Vergleich zeigt Ridge konsistentere Auswahlmuster als Lasso/EN.
- **Fold-Mehrheit ($\geq 3/5$ Falten)**: Lasso $n = 36$, Elastic Net $n = 40$, Ridge $n = 28$. Größere Mehrheitsmengen bei Lasso/EN deuten auf geringere Übereinstimmung der Nullkoeffizienten.
- **Leistung (mittlere Außen-CV)**: ROC-AUC Ridge 0,772, Elastic Net 0,771, Lasso 0,770; PR-AUC ca. 0,138–0,140. Die Unterschiede liegen im Bereich zufälliger Variation.
- **EPV-Implikation**: Bei gegebener Ereigniszahl E sind maximal $\lfloor E/10 \rfloor$ Variablen zulässig (Peduzzi et al., 1996; Steyerberg, 2019). Mehrheitsmengen oberhalb dieser Schranke werden im Konsensschritt gekappt.

Einordnung: Die prädiktiven Leistungen unterscheiden sich für H1 nur marginal; die PR-AUC bestätigt dies unter Klassenungleichgewicht (Saito and Rehmsmeier, 2015). Stabilität wird *relativ* interpretiert (Nogueira et al., 2018); im Vergleich weist Ridge robustere Muster auf. Für die Konsensbildung erhalten überlappende, stabile Merkmale größeres Gewicht; die EPV-Deckelung gewährleistet ökonometrische Vertretbarkeit. Damit liegen fokussierte, prüffähige Merkmalsmengen vor, die in Phase 05 als Eingangsgrößen für die Modellierung dienen, wo Generalisierung und Kalibrierung im Vordergrund stehen.

Hypothese vs. Beobachtung (H1)

Als *Hypothese* wurde anfänglich eine Rangfolge „Elastic Net > Random Forest > Lasso > Ridge“ diskutiert (Motivation: Gruppenstruktur korrelierter Kennzahlen). *Beobachtung (nested)*: In H1 liegen Lasso/Elastic Net/Ridge praktisch gleichauf ($\text{ROC-AUC} \approx 0,77$), mit einem leichten Vorteil für Ridge im alten Ansatz und einem konservativeren Wert unter Nested-CV. Die Unterschiede sind klein und im Bereich zufälliger Variation; maßgeblich für die Konsensbildung sind daher Stabilität und EPV-Vertretbarkeit.

Vergleich H1: Alter vs. verschachtelter Ansatz

Zur Einordnung werden die Ergebnisse des ursprünglichen (nicht-verschachtelten) Ansatzes den verschachtelten Werten gegenübergestellt (alle Kennzahlen empirisch aus `results/04_feature_selection/`):

Table 7.1: Vergleich H1: Alter vs. verschachtelter Ansatz

Methode	ROC-AUC alt	ROC-AUC nested	PR-AUC alt	PR-AUC nested
Lasso	0,7751	0,7700	0,1393	0,1375
Elastic Net	0,7707	0,7708	0,1390	0,1380
Ridge	0,7842	0,7724	0,1466	0,1396

Quelle: Eigene Darstellung basierend auf Feature Selection Ergebnissen

Der verschachtelte Ansatz liefert eine konservativere Leistungsschätzung (insb. Ridge, Konsistenz mit (Cawley and Talbot, 2010; Varma and Simon, 2006)) und ermöglicht die Stabilitätsbewertung. Da die Leistungsdifferenzen insgesamt gering sind, wird zur Wahrung des Zeitbudgets die Modellierungsphase zunächst auf Basis der *alten* H1–H5-Auswahlen durchgeführt; die verschachtelten Ergebnisse werden anschließend als Vergleich (Sensitivitätsanalyse) herangezogen.

Vergleich H2 und H3: Alter vs. verschachtelter Ansatz

H2 (Embedded, linear): Alte (nicht-verschachtelte) vs. Nested-CV Ergebnisse (ROC-AUC):

- Lasso: alt 0,7103 $\rightarrow$ nested 0,7085 ($\Delta = -0,0018$)
- Elastic Net: alt 0,7086 $\rightarrow$ nested 0,7096 ($\Delta = +0,0010$)
- Ridge: alt 0,7178 $\rightarrow$ nested 0,7082 ($\Delta = -0,0096$)

Interpretation: Nested reduziert insbesondere bei Ridge den anfänglichen Optimismus. Insgesamt konvergieren die drei Verfahren bei $\approx 0,709$; kein klarer Sieger. Stabilität (Nogueira): Ridge 0,508 > Lasso 0,240 > Elastic Net 0,137; für die Konsensbildung spricht dies für stärkere Gewichtung stabiler Kerne (Ridge/Lasso) und vorsichtige Nutzung breiter EN-Sets.

H3 (Embedded, linear): Alte (nicht-verschachtelte) vs. Nested-CV Ergebnisse (ROC-AUC):

- Lasso: alt 0,7381 $\rightarrow$ nested 0,7339 ($\Delta = -0,0042$)
- Elastic Net: alt 0,7416 $\rightarrow$ nested 0,7425 ($\Delta = +0,0009$)
- Ridge: alt 0,7384 $\rightarrow$ nested 0,7347 ($\Delta = -0,0037$)

Interpretation: Elastic Net bleibt knapp vorn, Unterschiede sind klein. Stabilität (Nogueira): Lasso 0,560 > Ridge 0,382 > Elastic Net 0,316. Ergebnis: Je Horizont unterscheiden sich sowohl Rangfolge als auch Stabilität; daher ist ein konsensorientierter, EPV-gestützter Ansatz über Horizonte hinweg sachgerecht.

H4 (Embedded, linear; verschachtelt): Nested-CV (mittlere Außenfalten-ROC-AUC): Lasso 0,758, Elastic Net 0,758, Ridge 0,755. Die Unterschiede sind klein; die *Stabilität* (Nogueira) ist Ridge 0,455 > Elastic Net 0,312 > Lasso 0,199 (H4). Damit bestätigt sich auch für H4: leichte Leistungsunterschiede, aber deutliche Stabilitätsunterschiede, was die Konsensorientierung stützt.

7.8 Aggregierte Übersichten

Die folgenden Tabellen fassen methodenspezifische Ergebnisse, Stabilitätskennzahlen und Konsensauswahlen zusammen. Die verschachtelten Stabilitätswerte werden fortlaufend ergänzt, sobald H2–H5 vorliegen.

7 Feature Selection




Figure 7.1: Konsens-Featureanzahl und AUC-Retention je Horizont (Basis: VIF-Featuremenge)

Quelle: Eigene Darstellung basierend auf 04d_ALL_consensus.xlsx

Methodenvergleich (ROC-AUC)

Table 7.2: Methodenvergleich (ROC-AUC)

Horizon	Method	ROC-AUC
H1	lasso	0.770
H1	elastic_net	0.771
H1	ridge	0.772
H1	random_forest	0.771
H2	lasso	0.709
H2	elastic_net	0.710
H2	ridge	0.708
H2	random_forest	0.709
H3	lasso	0.734
H3	elastic_net	0.743
H3	ridge	0.735
H3	random_forest	0.733
H4	lasso	0.758
H4	elastic_net	0.758
H4	ridge	0.755
H4	random_forest	0.747
H5	lasso	0.854
H5	elastic_net	0.852
H5	ridge	0.853
H5	random_forest	0.841

Quelle: Eigene Darstellung basierend auf results/04_feature_selection/

Stabilität über Falten (Nogueira)

Table 7.3: Stabilität über Falten (Nogueira)

Horizon	Method	Stability
H1	lasso	0.327
H1	elastic_net	0.050
H1	ridge	0.454
H2	lasso	0.240
H2	elastic_net	0.137
H2	ridge	0.508
H3	lasso	0.560
H3	elastic_net	0.316
H3	ridge	0.382
H4	lasso	0.199
H4	elastic_net	0.312
H4	ridge	0.455
H5	lasso	–
H5	elastic_net	–
H5	ridge	–

Quelle: Eigene Darstellung basierend auf `results/04_feature_selection/nested/`

Konsens und Guardrails

Table 7.4: Konsens und Guardrails

Horizon	Set	#Features	Retention (%)
H1	intersection	10	101.5
H2	intersection	9	96.5
H3	intersection	7	101.6
H4	intersection	8	97.6
H5	intersection	10	99.0

Quelle: Eigene Darstellung basierend auf `results/04_feature_selection/04d_ALL_consensus.xlsx`

7.9 Diagnostik und Robustheit

Unter Klassenungleichgewicht können bei Elastic Net Konvergenzhinweise auftreten; dem wird durch adaptive Erhöhung von `max_iter` und maßvolle Toleranzanpassung begegnet. Hyperparameter-Gitter werden so gesetzt, dass Rechenaufwand begrenzt und modelltheoretische Anforderungen (z. B. `saga` für Elastic Net) erfüllt werden (Hastie et al., 2009). Die Stabilitätsanalyse ergänzt die prädiktive Leistung als zweite Robustheitsachse.

Validierung theoriebasierter Entscheidungen: Die Feature Selection bestätigt exemplarisch die Robustheit der Pipeline. So wurde beispielsweise Kennzahl A37 (*Quick Assets / Long-term Liabilities*) trotz problematischer Imputationsqualität (43,7% fehlende Werte, Quality Score 25/100) in der Datenaufbereitung (Abschnitt 4.3) zunächst aus theoretischen Gründen beibehalten. Die datengetriebene Feature Selection eliminierte A37 jedoch über alle Horizonte hinweg aus den finalen Konsensmengen – eine Bestätigung, dass die Pipeline problematische Features algorithmisch identifiziert und entfernt, selbst wenn sie theoretisch plausibel erscheinen.

Die resultierenden, EPV-konformen Konsensmengen schließen nahtlos an Phase 05 an, in der diese Merkmalsmengen in logistischen Modellen und Waldverfahren als finale Inputs dienen und gegen Baselines gespiegelt werden.

8 Modellierung und Evaluation

Die Modellierung in dieser Phase erfolgt *zunächst* auf Basis der in Phase 04 (alter Ansatz) ermittelten, EPV-konformen Merkmalsmengen je Horizont. Die verschachtelten Ergebnisse (H1 bereits vorliegend) werden nach Abschluss als Sensitivitäts- und Robustheitsvergleich ergänzt (“alte Auswahl” vs. “nested-basierte Auswahl”).

8.1 Modellarchitekturen

8.1.1 Baseline: Logistische Regression

Eingesetzt wird eine Pipeline aus `StandardScaler` und logistischer Regression mit L2-Regularisierung (Solver `lbfgs`). Die Parameter folgen Phase 05: $C = 1,0$, `class_weight=balanced`, `max_iter=100000`, `tol=10-3`, `random_state=42`. Die Konfiguration ist über alle Horizonte identisch, um Vergleichbarkeit zu wahren. Die Bewertung erfolgt mit 5-fach stratifizierter Cross-Validation; Primärmetrik ist ROC-AUC, PR-AUC dient als Imbalance-sensitive Zweitmetrik.

8.1.2 Random Forest

Als baumbasierte Referenz wird ein `RandomForestClassifier` genutzt. Parameter (aus der Projektkonfiguration): `n_estimators=800`, `max_depth=20`, `min_samples_split=10`, `min_samples_leaf=5`, `max_features="sqrt"`, `class_weight="balanced_subsample"`, `n_jobs=6`, `random_state=42`. Diese Einstellungen sind für alle Horizonte konstant. Der Ansatz ist robust gegenüber Multikollinearität und liefert verlässliche Wahrscheinlichkeits-Scores für AUC-basierte Bewertung.

8.1.3 Gradient Boosting und weitere Modelle

Zusätzlich werden in Phase 05b weitere Verfahren geprüft: `GradientBoostingClassifier` (`random_state=42`), `ExtraTreesClassifier` (Parameter analog RF inkl. `class_weight`), sowie SVC in einer Skalierungs-Pipeline (`probability=True`, `class_weight=balanced`, `random_state=42`). Ein Soft-Voting-Ensemble kombiniert LR(L2, skaliert) + GB + ET (`voting="soft"`). Es findet keine umfangreiche Hyperparameter-Suche statt; die Konfiguration ist bewusst moderat und reproduzierbar gehalten.

8.2 Hyperparameter-Tuning

In Phase 05 erfolgt *keine* breit angelegte Hyperparameter-Optimierung. Ziel ist eine faire, replizierbare Gegenüberstellung der Modellfamilien unter EPV- und Rechenzeit-Gesichtspunkten. RF nutzt feste, in der Konfiguration dokumentierte Einstellungen; LR verwendet die o. g. Standardparameter. Für die Extra-Modelle werden ebenso konservative Defaults eingesetzt. Ausführliches Tuning und Kalibrierung sind als Erweiterung vorgesehen (vgl. Kap. 9).

8.2.1 Cross-Validation

Alle Modelle werden je Horizont mit 5-fach *stratifizierter* CV evaluiert (`shuffle=True`, `random_state=42`). Bewertet wird anhand vorhergesagter *Wahrscheinlichkeiten* (nicht Klassenlabels); Primärmetrik ist ROC-AUC, ergänzt um PR-AUC. Nested-CV wird in Phase 04 für die Feature-Selektion genutzt; die Modellvergleiche in Phase 05 erfolgen mit einheitlicher, nicht-verschachtelter CV zur transparenten Gegenüberstellung der Verfahren.

8.2.2 Horizontspezifisches Tuning

Spezifische Tuning-Schritte pro Horizont wurden *nicht* durchgeführt. Die Parameter bleiben konstant; Unterschiede in der Güte entstehen aus daten- und prävalenzbedingten Horizontunterschieden. Dies gewährleistet Vergleichbarkeit der Modelle über H1–H5.

8.3 Behandlung der Klassenimbalance

Die Klassenungleichgewichte werden über `class_weight` adressiert: LR nutzt `balanced`, RF `balanced_subsample`, SVC `balanced`. Es kommen *keine* Resampling-Verfahren zum Einsatz. Schwellen werden nicht optimiert; stattdessen werden schwellenunabhängige Flächenmetriken (ROC-/PR-AUC) berichtet. Kalibrierung und geschäftsfallbezogene Schwellenwahl folgen in Kap. 9.

8.4 Ergebnisse

Table 8.1: Modellgüte pro Horizont (beste ROC-AUC und PR-AUC)

Horizont	Bestes Modell	ROC-AUC	PR-AUC	Anzahl Features
H1	softvote_lr_gb_et	0.796	0.183	10
H2	random_forest	0.845	0.341	9
H3	random_forest	0.780	0.140	7
H4	random_forest	0.812	0.218	8
H5	random_forest	0.864	0.420	10

Zusätzlich fasst Tabelle 8.2 die jeweils besten Baseline-Modelle (LR/RF) den besten Extra-/Ensemble-Varianten sowie dem insgesamt besten Verfahren je Horizont gegenüber (primäre Optimierung: ROC-AUC). Dadurch wird transparent, in welchen Horizonten Ensemble- oder Boosting-Modelle die Baselines übertreffen und wo die lineare Referenz konkurrenzfähig bleibt.

Table 8.2: Baseline vs. Extra/Ensemble je Horizont (ROC-AUC)

Horizont	Baseline (Best)	ROC-AUC	Extra/Ensemble (Best)	ROC-AUC	Overall (Best)
H1	random_forest	0.795	softvote_lr_gb_et	0.796	softvote_lr_gb_et
H2	random_forest	0.845	gradboost	0.827	random_forest
H3	random_forest	0.780	gradboost	0.774	random_forest
H4	random_forest	0.812	gradboost	0.787	random_forest
H5	random_forest	0.864	softvote_lr_gb_et	0.858	random_forest

Ergänzende Gesamtübersicht

Table 8.3: Modellvergleich (ROC-AUC) – alle Modelle je Horizont (Phase 05, Base + Extra)

Model	H1	H2	H3	H4	H5
catboost	0.775	0.819	0.767	0.795	0.848
extratrees	0.773	0.757	0.771	0.774	0.857
gradboost	0.786	0.827	0.774	0.787	0.857
logreg_l2	0.783	0.685	0.744	0.740	0.838
logreg_l2_scaled	0.783	0.685	0.744	0.740	0.838
random_forest	0.795	0.845	0.780	0.812	0.864
softvote_lr_gb_et	0.796	0.777	0.771	0.773	0.858
svc_scaled	0.767	0.734	0.766	0.752	0.835

Quelle: Eigene Darstellung basierend auf `results/05_modeling/` und `results/05_modeling/extra/`

Kurzfasit (ROC-AUC, insgesamt Bestes je Horizont): H1 gewinnt das Soft-Voting-Ensemble (0,796), H2–H5 jeweils der Random Forest (0,845/0,780/0,812/0,864); damit dominiert der Random Forest in vier von fünf Horizonten, das Ensemble liegt in H1 knapp vorn.

PR-AUC der Sieger-Modelle. Ergänzend zur ROC-AUC werden die im Klassenungleichgewicht aussagekräftigeren PR-AUC-Werte berichtet (Saito and Rehmsmeier, 2015). Für die jeweils bestplatzierten Modelle je Horizont ergeben sich: H1 (Soft-Voting) 0,183; H2 (Random Forest) 0,341; H3 (Random Forest) 0,140; H4 (Random Forest) 0,218; H5 (Random Forest) 0,420 (vgl. Tab. 8.1). Die Werte sind konsistent mit der beobachteten Zunahme der Zielklassenprävalenz über die Horizonte (vgl. Kap. 3): PR-AUC steigt in späteren Horizonten tendenziell an.




Figure 8.1: Bestes Modell und ROC-AUC je Horizont

Quelle: Eigene Darstellung basierend auf `results/05_modeling/` und `extra/`

Hinweis zur Kalibrierung und Schwellenwahl. In dieser Phase wurden bewusst *keine* Wahrscheinlichkeitskalibrierung (Platt/Isoton) und *keine* geschäftsfallbezogene Schwellenoptimierung vorgenommen. Beides ist als eigenständiger Schritt mit klarer Kostenfunktion zu behandeln und wird in Kap. 9 als zukünftige Erweiterung vorgesehen. Für die vergleichende Bewertung werden daher primär schwellenunabhängige Flächenmetriken (ROC-/PR-AUC) herangezogen.

Abweichung zu archivierten Performanzangaben

Im historischen Archiv wird für den polnischen Datensatz ein Wert von “0,9812 (98,12% accuracy)” ausgewiesen (CatBoost, Einzel-Split). Diese Zahl ist aus heutigen Kriterien

als *explorativ und potenziell optimistisch* zu klassifizieren. Die wichtigsten Ursachen der Abweichung gegenüber den hier berichteten, moderateren ROC-AUC-Werten (ca. 0,80–0,86) sind:

- **Validierungsregime:** Archiv: einzelner Train/Test-Split ohne Wiederholungs- oder Faltungseffekte; hier: 5-fach stratifizierte Cross-Validation reduziert Varianz und Optimismus.
- **Metrik-Bezeichnung:** Im Archiv wird ROC-AUC mit “Accuracy” semantisch vermischt, was einen höheren Anschein klassifikatorischer Exaktheit suggeriert als tatsächlich vorliegt.
- **Feature-Selektion / EPV:** Archiv nutzte vor EPV-Remediation breitere, teils multikollineare Merkmalslisten; hier strikt EPV-konforme, redundanzreduzierte Sets (geringerer Overfit-Spielraum).
- **Modellkomplexität:** CatBoost (gradient boosting mit kategorialer Spezialbehandlung) war archiviert inkludiert und vermutlich feinjustiert; in dieser Phase wurde aus Reproduzierbarkeits- und Ressourcen-Gründen auf ein begrenztes, transparentes Set (LR, RF, GB, SVC, ExtraTrees, Voting) fokussiert.
- **Potenzielle Leckagen:** Einzel-Split ohne temporale Sensitivitätsprüfung erhöht Risiko strukturierter Zufallsartefakte; aktuelle Pipeline vermeidet dies durch methodische Reihenfolge (Foundation -> Selektion -> CV).
- **Klassenimbalance-Behandlung:** Archivwerte können von ungeeigneten Schwellen oder unkalibrierten Wahrscheinlichkeiten profitieren; hier werden `class_weight`-Adjustments konsistent angewandt und primär Schwellen-unabhängige Flächenmetriken (ROC-/PR-AUC) berichtet.

In Summe stellen die hier dokumentierten Ergebnisse eine *konservativere, robustere und publizierbare* Schätzung der generalisierbaren Modellgüte dar. Die archivierte CatBoost-Performanz ist als explorativer Obergrenz-Hinweis zu interpretieren, nicht als belastbare Replikationsbasis.

9 Limitations and Future Work

9.1 Unfinished Tasks (Computational Constraints)

- **Verschachtelte Auswahl H5:** Die verschachtelte (nested) Einbettung in Phase 04c ist für H1–H4 abgeschlossen; H5 ausstehend. Nach Abschluss: **04d** mit Nested-Inputs neu ausführen und **Phase 05** erneut mit Nested-Features evaluieren (Sensitivitätsvergleich alt vs. nested).
- **04b Wrapper-Fix erneut rechnen:** Die Konfigurationsbereinigung (Random State, LR-Defaults) in 04b wurde implementiert, jedoch noch nicht neu berechnet. Neuberechnung optional nach Abgabe.

9.2 Methodological Enhancements

Die in Kap. 8 zusammengefasste Bewertungsmatrix (vgl. Tab. 8.3) bietet eine kompakte Übersicht über die Verfahren je Horizont und dient als Ausgangspunkt für die folgenden Vertiefungen.

- **Group-aware Cross-Validation (Panel/Temporal Leakage):** Falls mehrere Jahre pro Firma vorliegen, sollten Beobachtungen derselben Firma nicht auf verschiedene Folds verteilt werden. Empfohlen: *GroupKFold* bzw. *StratifiedGroupKFold* in scikit-learn (scikit-learn developers, 2024b; scikit-learn developers, 2024a). Ohne eindeutige Firmen-ID ist dies nicht umsetzbar; wir dokumentieren die potentielle Leakage als Limitation.
- **Hyperparameter-Tuning je Horizont:** Systematische Suche (z. B. Random/Optuna) für RF/GB/ET/SVC/CatBoost mit konsistentem Nested-CV. Erwartung: moderate AUC-Gewinne, robustere Varianz.
- **Wahrscheinlichkeitskalibrierung & Schwellenanalyse:** Platt-Scaling bzw. Isotone Kalibrierung (*CalibratedClassifierCV*); Schwellenwahl nach Kostenfunktion (Type-I/II-Kosten) und PR-Kurven. Zusätzliche Metriken: Brier Score, Expected Calibration Error.
- **Konsens unter Stabilitäts-Guides:** Nutzung der Nogueira-Stabilität aus Nested-Outputs als Gewichtung/Filter in 04d (z. B. Mindeststabilität), anstelle reiner Schnitt-/Mehrheitsmengen.

- **Zeitliche Validierung:** Falls zeitliche Ordnung rekonstruierbar ist: rollierende/geblockte CV, um Vorwärts-Prognose realistisch zu simulieren.
- **Interpretierbarkeit:** SHAP für Baumverfahren; Konfidenzintervalle/Bootstrap für Logit-Koeffizienten; Stabilität der Koeffizienten über Folds.

9.3 Cross-Dataset Generalization

- **Polish → American/TEJ:** Abbildung semantischer Kategorien (Profitabilität, Liquidität, Leverage, etc.) auf andere Datensätze (Konfigurationsdatei `semantic_categories`). Vergleich der Konsens-Features und der Sieger-Modelle je Horizont.

9.4 Runtime Engineering

- **Grid-Reduktion und Checkpointing:** Kleinere C-Grids für Elastic Net, adaptive `max_iter/tol`; Zwischenspeicherung foldweiser Ergebnisse zur Wiederaufnahme.
- **Parallelisierung/HPC:** Nutzung aller Kerne (`n_jobs`) und optional HPC-Cluster; erwartete Beschleunigung v. a. in Nested-EN.

9.5 Documented Limitations

- **Panel-Leckage-Risiko:** Ohne Gruppen-IDs (Firma/Jahr) kann Stratifikation allein nicht verhindern, dass Firmensamples über Folds geteilt werden. Dies ist als potentielle Quelle leichten Optimismus dokumentiert; künftige Arbeiten sollten *StratifiedGroup-KFold* verwenden, sobald Gruppen verfügbar sind (scikit-learn developers, 2024b; scikit-learn developers, 2024a).
- **Nicht-nested Endauswahl im alten Ansatz:** Endgültige Auswahlen in 04a/04c (alt) sind leicht optimistisch; Nested-Ergebnisse (H1–H3) quantifizieren diesen Effekt und werden nachlaufend für H4–H5 ergänzt.

10 Conclusion

Diese Arbeit verbindet klassische Bilanzlogik mit moderner, reproduzierbarer Datenanalyse zu einem kompakten Frühwarnsystem. Kern ist eine Pipeline, die (a) Multikollinearität systematisch abbaut (VIF), (b) Features über Filter-, Wrapper- und Embedded-Methoden selektiert und deren Robustheit mit Nested-CV und dem Stabilitätsmaß nach Nogueira et al. (2018) prüft, (c) EPV- Leitplanken berücksichtigt und (d) konsensorientierte Endmengen bildet. Auf Basis dieser Sets zeigt der Modellvergleich über fünf Horizonte, dass ein Random Forest in vier von fünf Fällen die höchste ROC-AUC erzielt, während ein Soft-Voting-Ensemble bei kurzer Frist (H1) knapp vorn liegt. Bemerkenswert ist, dass kleine, stabile Merkmalsmengen die Güte der Vollmengen weitgehend halten (AUC-Retention ca. 97–102%) und damit Interpretierbarkeit und Verallgemeinerbarkeit fördern.

Methodisch tragen drei Entscheidungen wesentlich zur Glaubwürdigkeit bei: (1) klare Trennung von Auswahl und Bewertung (Nested-CV in der Selektion, stratifizierte CV in der Modellierung), (2) Stabilität als Qualitätskriterium für Merkmalslisten, (3) EPV-Disziplin, um Überparametrisierung zu vermeiden. Diese Maßnahmen reduzieren Optimismus und erleichtern eine ehrliche Projektdokumentation.

Praktisch bietet die Pipeline einen Einstieg für Kredit- und Risikofunktionen, die auf interpretierbare Kennzahlen, schlanke Modelle und stabile Entscheidungen angewiesen sind. Künftige Arbeit (Kap. 9) liegt in gruppenbewusster CV (sofern Firmen-IDs verfügbar), Kalibrierung und Schwellenwahl mit Kostenfunktion, systematischem Hyperparameter-Tuning, stabilitätsgewichteter Konsensbildung sowie temporalen Validierungsschemata. Damit lässt sich die hier gezeigte Robustheit weiter in Richtung operativer Umsetzung entwickeln.

Bibliography

- Altman, Edward I. (1968). „Financial Ratios, Discriminant Analysis and the Prediction of Corporate Bankruptcy“. In: *The Journal of Finance* 23.4, pp. 589–609. DOI: 10.2307/2978933.
- Barboza, Flavio, Herbert Kimura, and Edward Altman (2017). „Machine Learning Models and Bankruptcy Prediction“. In: *Expert Systems with Applications* 83, pp. 405–417. DOI: 10.1016/j.eswa.2017.04.006.
- Benjamini, Yoav and Yosef Hochberg (1995). „Controlling the False Discovery Rate: A Practical and Powerful Approach to Multiple Testing“. In: *Journal of the Royal Statistical Society. Series B (Methodological)* 57.1, pp. 289–300. DOI: 10.1111/j.2517-6161.1995.tb02031.x.
- Buuren, Stef van (2018). *Flexible Imputation of Missing Data*. 2nd. Boca Raton, FL: Chapman and Hall/CRC. DOI: 10.1201/9780429492259.
- Buuren, Stef van and Karin Groothuis-Oudshoorn (2011). „mice: Multivariate Imputation by Chained Equations in R“. In: *Journal of Statistical Software* 45.3, pp. 1–67. DOI: 10.18637/jss.v045.i03.
- Cawley, Gavin C. and Nicola L. C. Talbot (2010). „On over-fitting in model selection and subsequent selection bias in performance evaluation“. In: *Journal of Machine Learning Research* 11, pp. 2079–2107.
- Coats, Pamela K. and L. Franklin Fant (1993). „Recognizing Financial Distress Patterns Using a Neural Network Tool“. In: *Financial Management* 22.3, pp. 142–155. DOI: 10.2307/3665934.
- Cohen, Jacob (1988). *Statistical Power Analysis for the Behavioral Sciences*. 2nd. Hillsdale, NJ: Routledge. ISBN: 978-0805802832.
- D’Agostino, Ralph B. and E. S. Pearson (1973). „Tests for Departure from Normality. Empirical Results for the Distributions of b_2 and $\sqrt{b_1}$ “. In: *Biometrika* 60.3, pp. 613–622. DOI: 10.1093/biomet/60.3.613.
- Goodfellow, Ian, Yoshua Bengio, and Aaron Courville (2016). *Deep Learning*. Cambridge, MA: MIT Press. URL: <http://www.deeplearningbook.org>.
- Guyon, Isabelle and André Elisseeff (2003). „An Introduction to Variable and Feature Selection“. In: *Journal of Machine Learning Research* 3, pp. 1157–1182.
- Hastie, Trevor, Robert Tibshirani, and Jerome Friedman (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. 2nd. New York: Springer. ISBN: 978-0-387-84857-0.

Bibliography

- Hippel, Paul T. von (2013). „Multiple Imputation for an Incomplete Covariate that is a Ratio“. In: *Statistics in Medicine* 32.26, pp. 4527–4544. DOI: 10.1002/sim.5935.
- Levene, Howard (1960). „Robust Tests for Equality of Variances“. In: *Contributions to Probability and Statistics: Essays in Honor of Harold Hotelling*. Ed. by Ingram Olkin, S. G. Ghurye, Wassily Hoeffding, William G. Madow, and Henry B. Mann. Palo Alto, CA: Stanford University Press, pp. 278–292.
- Mann, Henry B. and Donald R. Whitney (1947). „On a Test of Whether One of Two Random Variables Is Stochastically Larger Than the Other“. In: *The Annals of Mathematical Statistics* 18.1, pp. 50–60. DOI: 10.1214/aoms/1177730491.
- McLeay, Stuart and Abdulkadir Omar (2000). „The Sensitivity of Prediction Models to the Non-Normality of Bounded and Unbounded Financial Ratios“. In: *British Accounting Review* 32.2, pp. 213–230. DOI: 10.1006/bare.1999.0120.
- Meinshausen, Nicolai and Peter Bühlmann (2010). „Stability selection“. In: *Journal of the Royal Statistical Society: Series B (Statistical Methodology)* 72.4, pp. 417–473. DOI: 10.1111/j.1467-9868.2010.00740.x.
- Nogueira, Sarah, Konstantinos Sechidis, and Gavin Brown (2018). „On the Stability of Feature Selection Algorithms“. In: *Journal of Machine Learning Research* 18.174, pp. 1–54.
- O’Brien, Robert M. (2007). „A Caution Regarding Rules of Thumb for Variance Inflation Factors“. In: *Quality & Quantity* 41.5, pp. 673–690. DOI: 10.1007/s11135-006-9018-6.
- Peduzzi, P., J. Concato, E. Kemper, T. R. Holford, and A. R. Feinstein (1996). „A simulation study of the number of events per variable in logistic regression analysis“. In: *Journal of Clinical Epidemiology* 49.12, pp. 1373–1379. DOI: 10.1016/S0895-4356(96)00236-3.
- Penn State Eberly College of Science (2024). *Detecting Multicollinearity Using Variance Inflation Factors*. STAT 462: Applied Regression Analysis, Online Course. Accessed: November 18, 2024. URL: <https://online.stat.psu.edu/stat462/node/180/>.
- Rudin, Cynthia (2019). „Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead“. In: *Nature Machine Intelligence* 1, pp. 206–215. DOI: 10.1038/s42256-019-0048-x.
- Saito, Takaya and Marc Rehmsmeier (2015). „The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets“. In: *PLoS ONE* 10.3, e0118432. DOI: 10.1371/journal.pone.0118432.
- Schober, Patrick, Christa Boer, and Lothar A. Schwarte (2018). „Correlation Coefficients: Appropriate Use and Interpretation“. In: *Anesthesia & Analgesia* 126.5, pp. 1763–1768. DOI: 10.1213/ANE.0000000000002864.
- scikit-learn developers (2024a). *Cross-validation: evaluating estimator performance*. scikit-learn User Guide. Accessed: November 2025. URL: https://scikit-learn.org/stable/modules/cross_validation.html.

Bibliography

- scikit-learn developers (2024b). *GroupKFold*. scikit-learn documentation. Accessed: November 2025. URL: https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GroupKFold.html.
- Steyerberg, Ewout W. (2019). *Clinical Prediction Models*. 2nd. Cham: Springer. DOI: 10.1007/978-3-030-16399-0.
- Sun, Jie, Hui Li, Qing-Hua Huang, and Kai-Yu He (2024). „Bankruptcy Prediction Using Machine Learning and Data Preprocessing Techniques“. In: *Analytics* 4.3, p. 22. DOI: 10.3390/analytics4030022.
- Tipping, Michael E. (2001). „Sparse Bayesian Learning and the Relevance Vector Machine“. In: *Journal of Machine Learning Research* 1, pp. 211–244.
- Varma, Sudhir and Richard Simon (2006). „Bias in error estimation when using cross-validation for model selection“. In: *BMC Bioinformatics* 7.1, p. 91. DOI: 10.1186/1471-2105-7-91.
- Wooldridge, Jeffrey M. (2010). *Econometric Analysis of Cross Section and Panel Data*. 2nd. Cambridge, MA: MIT Press. ISBN: 978-0-262-23258-6.
- Zięba, Maciej, Sebastian K Tomczak, and Jarosław M Tomczak (2016). „Ensemble boosted trees with synthetic features generation in application to bankruptcy prediction“. In: *Expert Systems with Applications* 58, pp. 93–101. DOI: 10.1016/j.eswa.2016.03.033.